

深圳大学考试答题纸

(以论文、报告等形式考核专用)
二〇二五~二〇二六学年度第二学期

课程编号 1501990047 课序号 01 课程名称 人工智能伦理 主讲教师 ZHANG LIANGJIE 评分

座位号: 03 学号: 2024150040 姓名: 邓瑞霖 专业年级: 2024 级人工智能卓越班

教师评语:

题目:

AI 智能体的伦理风险与治理策略研究

摘要

2025 年至 2026 年, 人工智能技术正经历从"内容生成工具"向"智能体系统" (AI Agent) 的范式跃迁。AI 智能体不仅具备语言理解和生成能力, 更拥有任务规划、工具调用、自主决策和持续行动等能力, 正在深刻重塑教育、医疗、金融、政务、科研等关键社会领域。然而, 智能体系统的自主性与行动能力也带来了前所未有的伦理挑战: 幻觉导致的错误决策、未经授权的隐私访问、算法偏见的系统性放大、责任归属的模糊化, 以及深度伪造与网络攻击等恶意滥用风险。本文从计算机伦理学的理论框架出发, 系统分析 AI 智能体的正面与负面社会影响, 探讨监管与创新之间的张力平衡, 深入剖析职业责任、隐私保护、知识产权、算法公平和安全风险等核心伦理议题, 并结合真实案例提出面向未来的 AI 智能体伦理治理策略。本文主张构建"分级分类、人机共责、透明可溯、动态迭代"的多层次治理体系, 以实现技术创新与伦理约束的动态平衡。

关键词: AI 智能体; 计算机伦理; 隐私保护; 算法偏见; 责任归属; 伦理治理

1. 引言

人工智能技术的发展正站在一个历史性的拐点上。以 GPT-4、Claude、Gemini 等大语言模型为代表的基础能力层持续进化，而在此之上构建的 AI 智能体（AI Agent）系统则代表了人工智能应用范式的根本性转变。与传统的聊天机器人不同，AI 智能体具备任务分解与规划、外部工具调用、环境感知与反馈、多步骤自主执行等核心能力[1]。它们不再仅仅“回答问题”，而是能够“完成任务”——从预订机票、管理日程到编写代码、分析数据、参与金融交易，甚至在企业 workflows 中承担端到端的自动化角色。

这一技术跃迁带来了巨大的社会价值预期。据 MarketsandMarkets 预测，全球 AI 智能体市场规模将从 2025 年的 51 亿美元增长至 2030 年的 471 亿美元，年复合增长率高达 44.8%[2]。微软、谷歌、Meta、OpenAI、Anthropic 等科技巨头均将 AI 智能体列为最重要的战略方向。与此同时，AI 智能体的自主性和行动能力也引发了一系列深刻的伦理关切。2025 年 3 月，一名用户在使用 AI 智能体处理工作邮件时，系统因上下文理解错误向客户的竞争对手发送了包含敏感商业信息的邮件，造成严重的商业机密泄露。2025 年 6 月，某招聘平台部署的 AI 智能体被发现系统性地降低女性求职者的评分，引发广泛的算法歧视争议。这些案例表明，AI 智能体的伦理风险已不再是理论假设，而是正在发生的现实问题。

在此背景下，如何在鼓励 AI 智能体创新应用的同时，建立合理的伦理边界、责任机制和治理策略，已成为人工智能伦理领域的核心议题。欧盟《人工智能法案》（EU AI Act）已于 2024 年正式通过并将于 2026 年起分阶段实施，中国《生成式人工智能服务管理暂行办法》于 2023 年施行后也在持续完善，《人工智能法》已被列入全国人大常委会 2025 年度立法工作计划[3]。这些政策信号表明，全球主要经济体均在加速构建 AI 治理的法律框架。

本文围绕 AI 智能体的伦理问题，从四个维度展开系统研究：第一，分析 AI 智能体在典型应用场景中的正面与负面社会影响；第二，探讨加强监管与鼓励开放创新之间的利弊权衡；第三，从计算机伦理学的理论视角出发，系统剖析 AI 智能体涉及的职业责任、隐私保护、知识产权、算法偏见和安全风险等关键伦理问题；第四，结合真实案例，提出面向未来的 AI 智能体伦理治理策略。

2. AI 智能体的典型应用场景及其社会影响分析

2.1 典型应用场景概述

AI 智能体正在快速渗透到社会经济的各个领域。不同于传统 AI 系统需要在人类明确指令下运行，AI 智能体能够理解高层次目标、自主分解子任务、调用各类工具和 API、根据环境反馈动态调整策略，并在一定范围内实现端到端的任务闭环[4]。以下从教育、办公、医疗、金融、政务、科研和内容生产七个场景梳理其典型应用。

教育场景：AI 智能体可作为个性化学习导师，根据学生的学习进度、知识盲区和认知风格动态调整教学内容和节奏。例如，可汗学院推出的 Khanmigo 智能体基于 GPT-4，能够以苏格拉底式对话引导学生独立思考，而非直接给出答案。在国内，学而思、作业帮等平台也在部署基于大模型的 AI 答疑智能体，覆盖数学、物理、英语等多个学科。

办公场景：办公场景是 AI 智能体应用最为广泛的领域之一。微软 Copilot 深度集成于 Office 365 和 Teams 中，能够自动生成会议纪要、起草邮件、分析 Excel 数据、制作 PPT 演示文稿。Salesforce 的 Agentforce 平台允许企业构建自定义销售和服务智能体，自动处理客户查询、更新 CRM 记录、生成销售报告。Notion AI 和飞书智能伙伴也在文档协作、知识管理和项目跟踪方面展现出显著效能。

医疗场景：在医疗领域，AI 智能体被用于辅助诊断、病历整理、药物研发和患者管理。Google 的 Med-PaLM 2 在医学问答基准测试中达到专家级水平，能够分析医学影像报告、提供鉴别诊断建议。AI 智能体还可以自动整理电子健康记录（EHR）、提醒患者服药、安排随访，减轻医护人员的工作负担。在药物研发方面，AI 智能体能够加速靶点发现、分子设计和临床试验匹配。

金融场景：金融行业是 AI 智能体应用的先行者。Bloomberg GPT 和摩根大通的 IndexGPT 等金融智能体可进行市场分析、风险评估、投资组合优化和自动化交易。AI 智能体还可用于反欺诈监控、信用评估、客户服务和合规审查。然而，算法交易智能体的自主决策也可能引发市场波动甚至“闪崩”风险。

政务场景：政府部门开始尝试利用 AI 智能体提升公共服务效率。例如，AI 智能体可用于自动处理市民咨询、辅助政策文件起草、分析社会经济数据、监测舆情。深圳市在“i 深圳”APP 中集成了 AI 政务助手，可回答市民关于社保、公积金、出入境等业务的咨询。但政务场景中 AI 智能体的使用也涉及公民隐私保护和公共决策透明度的敏感问题。

科研场景：AI 智能体正在成为科学研究的新工具。它们可以自动阅读和总结学术文献、设计实验方案、分析实验数据、甚至提出新的研究假设。2025 年，斯坦福大学的研究团队利用 AI 智能体在短短三个月内完成了对 10 万篇生物医学文献的系统综述，此前类似工作需要数十名研究人员花费一年时间。Nature 杂志的调查显示，超过 60% 的科研人员已在研究中使用 AI 工具。

内容生产场景：AI 智能体在文本写作、视频制作、音乐创作、代码生成等内容生产领域展现了强大的能力。但与简单的内容生成不同，内容生产类 AI 智能体能够自主规划内容策略、管理多平台发布、监测传播效果并进行优化迭代。然而，这也带来了深度伪造、版权侵权和虚假信息传播等严重问题。

2.2 正面社会影响

AI 智能体的广泛应用为社会带来了多维度的积极影响。以下从效率提升、成本降低、决策辅助、个性化服务和弱势群体赋能五个方面进行系统分析。

2.2.1 显著提高生产效率与工作质量

AI 智能体通过自动化重复性、规则性任务，释放了人类劳动者的大量时间和精力，使其能够专注于需要创造性思维、情感智能和复杂判断的高价值工作。在软件开发领域，GitHub Copilot 和 Cursor 等 AI 智能体能够根据自然语言描述自动生成代码、调试错误、编写单元测试，将开发者的编码效率提升 30% 至 55%[5]。在法律行业，AI 智能体可在数分钟内完成以往需要初级律师数天才能完成的合同审查和判例检索工作。麦肯锡全球研究院的报告估计，生成式 AI 和 AI 智能体有望每年为全球经济增加 2.6 万亿至 4.4 万亿美元的价值[6]。

2.2.2 大幅降低服务获取成本

AI 智能体使高质量服务的边际成本趋近于零，从而大幅降低了专业服务的获取门槛。在医疗领域，AI 智能体可以为基层医疗机构提供接近三甲医院水平的辅助诊断建议，有助于缓解优质医疗资源分布不均的问题。在教育领域，AI 智能体为每个学生提供“一对一”个性化辅导的成本远低于聘请人类私教，有助于促进教育公平。在法律援助方面，AI 智能体可以帮助低收入群体理解法律条款、撰写简单法律文书[7]。

2.2.3 增强决策的科学性和全面性

AI 智能体能够在海量数据中快速识别模式、提取洞察，为人类决策者提供更加全面和客观的参考依据。在金融投资中，AI 智能体可同时追踪数百个市场指标和新闻源，辅助投资者做出更加理性的决策。在公共政策制定中，AI 智能体可以模拟不同政策方案的社会经济影响，为政策优化提供数据支撑。在企业战略规划中，AI 智能体能够整合市场趋势、竞争格局和内部运营数据，辅助管理层进行 SWOT 分析和战略选择。

2.2.4 促进个性化服务与适应性学习

AI 智能体具有强大的个性化能力，能够根据用户的行为模式、偏好特征和实时需求动态调整服务内容和交互方式。在教育场景中，AI 智能体可以根据每个学生的知识掌握程度、学习风格和注意力特征，提供差异化的教学内容和练习题目，实现真正的“因材施教”。在医疗健康领域，AI 智能体可以根据患者的基因特征、病史和生活方式，提供个性化的健康管理方案和用药建议。

2.2.5 增强弱势群体的社会参与能力

AI 智能体技术为残障人士、老年人和语言少数群体等弱势人群提供了前所未有的赋能工具。视障人士可以通过 AI 智能体“观看”周围环境、阅读文档、识别面孔；听障人士可以通过 AI 智能体实时转写对话内容；老年人可以通过 AI 智能体获得陪伴、健康提醒和紧急求助支持；非母语者可以通过 AI 智能体克服语言障碍，参与跨国交流和协作。微软的 Seeing AI 项目和谷歌的 Project Relate 等均已展示了 AI 技术在无障碍领域的巨大潜力。

2.3 负面社会影响

尽管 AI 智能体带来了显著的社会效益，其负面社会影响同样不容忽视。以下从六个维度进行系统分析。

2.3.1 错误决策与“幻觉”风险

大语言模型固有的“幻觉”（Hallucination）问题——即模型生成看似合理但事实错误的内容——在 AI 智能体中被进一步放大。当智能体不仅生成文本，还基于错误信息采取实际行动时，其后果可能是灾难性的。2025 年，一名加拿大用户在 Reddit 上报告，其使用的 AI 旅行规划智能体错误地将酒店预订到了同名的另一个城市，导致旅行计划完全打乱并造成数百加元的损失。在法律领域，2024 年美国纽约联邦法院对律师提交包含 AI 虚构案例的法律文件进行了制裁，凸显了在法律等高风险领域依赖 AI 智能体的潜在危险[8]。

更令人担忧的是，AI 智能体的“自信幻觉”特征——即系统对错误输出表现出高度确信的语气——使得用户难以辨别其提供信息的真伪。与搜索引擎提供多个来源供用户自行判断不同，AI 智能体往往以单一、确定的答案呈现，这种“认知权威性”的假象可能使用户过度信任系统，降低独立验证的意愿。

2.3.2 隐私泄露与数据安全威胁

AI 智能体在运行过程中通常需要访问大量用户数据，包括个人通信记录、日程安排、文件内容、位置信息、消费记录等敏感信息。智能体的“工具使用”能力意味着它们可能主动读取、传输和存储用户数据，这带来了巨大的隐私保护挑战。2025 年 5 月，安全研究人员发现某主流 AI 智能体平台存在漏洞，攻击者可利用“间接提示注入”（Indirect Prompt Injection）技术，通过向智能体处理的文档中嵌入隐藏指令，诱导智能体泄露用户的个人数据[9]。

此外，AI 智能体的“过度索取权限”问题也日益突出。许多 AI 智能体在安装时要求广泛的系统权限（如读取所有文件、访问通讯录、发送邮件等），而这些权限与其声称的功能往往不相匹配。用户普遍缺乏对 AI 智能体数据收集和处理行为的有效知情和控制手段。

2.3.3 责任归属模糊化

AI 智能体的自主决策能力对传统的责任归属框架构成了根本性挑战。当 AI 智能体造成损害时，责任应该归于谁？是开发底层模型的公司（如 OpenAI、Anthropic）？是构建智能体应用的开发者？是部署和使用智能体的企业？还是对智能体发出指令的终端用户？这一“多手问题”（Many Hands Problem）使得责任链条异常复杂[10]。

传统侵权法中的过错责任原则建立在“可预见性”和“可控制性”的基础上，但 AI 智能体的行为往往具有不可预见性和非完全可控性。2024 年，一家加拿大航空公司因 AI 客服智能体向乘客提供错误退款承诺而被法院判决承担责任，但航空公司辩称其不应为 AI 的“自创政策”负责。该案暴露了现行法律框架在处理 AI 智能体责任问题上的重大缺陷[11]。

2.3.4 就业结构冲击与技能贬值

AI 智能体的自动化能力不仅威胁蓝领工作岗位，更开始冲击白领和知识工作者的职业安全。与传统自动化不同，AI 智能体能够执行需要认知能力的任务，包括数据分析、报告撰写、代码编写、设计创作等。世界经济论坛《2025 年未来就业报告》指出，AI 和智能体技术将在 2025-2030 年间导致全球约 9200 万个工作岗位被替代，同时创造约 1.7 亿个新岗位，净增长约 7800 万个，但这一结构性转变将给大量劳动者带来再培训和转型的巨大压力[12]。

特别值得关注的是，AI 智能体可能引发“技能贬值”（Skill Devaluation）效应。当初级专业人员过度依赖 AI 智能体完成基础性工作，他们可能失去通过实践积累经验和培养专业判断力的机会。医学教育领域已有研究警告，医学生过度使用 AI 辅助诊断工具可能导致临床推理能力的下降[13]。

2.3.5 算法偏见与歧视的系统性放大

AI 智能体继承和放大了训练数据中存在的偏见，并因其自主决策能力而将这些偏见转化为具有实际社会后果的歧视行为。2025 年的一项研究发现，当 AI 智能体被用于简历筛选时，如果训练数据中包含历史招聘中的性别偏见，智能体不仅会复制这种偏见，还可能因“过度泛化”而将其扩展到与性别无关的其他特征上，造成更加广泛和隐蔽的歧视[14]。

算法偏见在 AI 智能体中的表现形式更为多样和隐蔽。除了直接的群体统计歧视外，还存在“代理歧视”（Proxy Discrimination）——即使用与受保护特征（如种族、性别）高度相关的其他变量作为替代进行不平等对待；以及“反馈循环放大”——即智能体的偏见决策改变现实数据分布，进一步强化未来的偏见。例如，如果 AI 信贷审批智能体系统性地拒绝特定社区的贷款申请，该社区的经济指标将恶化，进而“证实”智能体最初的负面评估[15]。

2.3.6 恶意滥用与安全威胁

AI 智能体的工具调用和自主执行能力为恶意行为者提供了前所未有的攻击手段。与传统 AI 模型主要停留在信息层面不同，AI 智能体可以实施具有实际物理或经济后果的攻击。欧盟刑警组织（Europol）在其 2025 年《AI 犯罪威胁评估报告》中指出，AI 智能体已被用于以下恶意活动：自动化钓鱼和社会工程攻击——AI 智能体可根据目标人物的社交媒体信息自动生成高度个性化的钓鱼邮件和诈骗消息，大幅提高攻击成功率；规模化虚假信息传播——AI 智能体可自主管理数百个社交媒体账号，协调发布虚假信息，制造舆论操纵效应；自动化漏洞扫描与利用——AI 智能体可自动搜索软件漏洞、生成利用代码并发起攻击，降低网络犯罪的技术门槛；深度伪造与身份冒充——AI 智能

体可结合语音克隆、面部生成和实时交互能力，冒充特定个人进行诈骗[16]。

表 1 AI 智能体典型应用场景正负社会影响汇总

应用场景	典型应用形式	正面影响	负面影响	风险等级
教育	个性辅导、自动批改、学习路径规划	促进教育公平、提高学习效率、减轻教师负担	学术诚信危机、学生过度依赖、教育评价偏差	中
办公	邮件处理、文档生成、会议纪要、数据分析	大幅提升效率、降低人工成本、优化协作流程	机密信息泄露、错误决策传播、职业替代	高
医疗	辅助诊断、病历管理、药物研发、患者随访	提高诊断准确率、缓解医疗资源不均、加速药物研发	误诊风险、患者隐私泄露、医患责任不清	极高
金融	算法交易、风险评估、信用审批、反欺诈	提升交易效率、优化资产配置、降低金融风险	市场系统性风险、信贷歧视、算法操纵	极高
政务	政策分析、市民服务、舆情监测、文件起草	提升服务效率、辅助科学决策、降低行政成本	公民隐私威胁、决策黑箱、数字鸿沟	高
科研	文献综述、实验设计、数据分析、假设生成	加速科研进程、促进跨学科创新、降低研究成本	学术不端风险、研究质量下降、科研诚信危机	中
内容生产	写作、视频、音乐、代码自动生成	降低创作门槛、丰富内容供给、提升生产效率	版权侵权、深度伪造、虚假信息泛滥、创作者权益受损	高

3. AI 智能体监管与创新自由的平衡讨论

AI 智能体的技术特征——自主性、行动能力和广泛的社会渗透性——决定了对其施以有效监管的必要性和紧迫性。然而，监管的力度、方式和时机同样需要审慎权衡。

3.1 加强监管的必要性与潜在风险

3.1.1 加强监管的必要性

保护公众安全与基本权利：AI 智能体在社会关键领域的广泛应用意味着其失效或滥用的代价极为高昂。在医疗领域，一个诊断建议错误可能导致患者延误治疗甚至死亡；在金融领域，算法交易智能体的失控可能引发市场剧烈波动和系统性风险；在司法领域，带有偏见的 AI 辅助决策可能导致不公正的裁判。监管是保护公众基本权利和安全的必要屏障。欧盟《人工智能法案》将医疗、司法、关键基础设施等领域的 AI 应用列为“高风险”类别，要求强制性合规评估，正是基于这一逻辑[17]。

减少信息不对称与权力失衡：AI 智能体的开发者和部署者通常掌握着关于系统能力、局限性和风险的信息优势，而终端用户、消费者和受影响公众则处于信息劣势。这种信息不对称可能导致用户过度信任系统、做出不利于自身利益的决策。监管可以强制信息披露和透明度要求，帮助公众做出更加理性的选择。例如，中国《生成式人工智能服务管理暂行办法》要求服务提供者对 AI 生成内容进行显著标识，即为减少信息不对称的制度设计[18]。

明确责任边界与救济渠道：如前所述，AI 智能体的多主体参与特征使得责任归属极为复杂。没有明确的法律规则，受害者将难以获得有效救济，而开发者和部署者也可能因责任不确定而过度保

守或过度冒险。监管可以通过建立责任规则、强制保险要求、设立行业赔偿基金等方式，为各方提供明确的行为预期和救济保障。

防止"逐底竞争"与道德风险：在缺乏统一监管框架的情况下，企业可能为了市场竞争而牺牲安全投入和伦理考量，形成"逐底竞争"（Race to the Bottom）的局面。最低限度的监管标准可以创造公平竞争环境，防止负责任的企业因承担更高的合规成本而在竞争中处于劣势。

3.1.2 加强监管的潜在风险

创新抑制效应：过度严格或设计不当的监管可能显著增加创新成本，阻碍技术发展。初创企业和小型开发者可能因无法承担高昂的合规成本而被排除在市场之外，导致行业集中度进一步提高。欧盟 AI 法案曾因合规要求过于复杂而遭到 Airbus、Siemens 等 150 多家欧洲企业的联名公开信批评，警告过度监管将削弱欧洲在全球 AI 竞争中的地位[19]。

监管滞后与错配：AI 技术的发展速度远快于立法和监管的节奏。监管机构面临"科林格里奇困境"（Collingridge Dilemma）——在技术早期，信息不足以制定精准监管；而当技术成熟、风险清晰时，技术路径已经锁定，改变成本极高。过度依赖规则式的事前监管（如技术标准的具体规定）可能很快落后于技术发展，而过于宽泛的原则式监管又可能缺乏有效执行力。

合规成本转嫁与数字鸿沟扩大：监管合规成本最终将转嫁给消费者，可能导致 AI 智能体服务价格上涨，使得低收入群体和中小企业更难获得先进技术，加剧数字鸿沟。研究显示，欧盟 GDPR 实施后，欧洲科技初创企业的融资额下降了约 20%，小型广告技术公司的市场份额被谷歌和 Facebook 等巨头进一步侵蚀[20]。

跨境监管冲突与碎片化：全球 AI 监管格局呈现碎片化特征——欧盟强调风险分级和基本权利保护，美国侧重行业自律和创新促进，中国注重内容安全和公共利益。这种碎片化可能导致跨国 AI 企业面临相互冲突的合规要求，增加全球性挑战（如 AI 安全、跨境执法协作）的治理难度。

表 2 加强 AI 智能体监管的利弊分析

分析维度	有利方面	不利方面	典型案例/数据
公共安全	建立安全底线，防止高风险场景的事故和滥用	过度谨慎可能阻碍有益应用（如 AI 辅助罕见病诊断）	欧盟 AI 法案高风险分类制度
权利保护	为隐私、平等、尊严等基本权利提供制度保障	刚性规则难以适应多元文化和社会情境的差异化需求	GDPR 对 AI 决策的“解释权”规定
创新激励	平等竞争环境激励“负责任创新”	合规成本可能压制中小企业创新活力	GDPR 后欧洲科技投资变化
责任明确	为受害者提供清晰的追责路径和救济渠道	责任规则可能诱导“防御性开发”和过度保守	加拿大航空 AI 客服案
国际竞争	高标准监管可能成为技术质量的“品牌标签”	碎片化监管增加跨境运营成本	欧盟企业联名信警告过度监管
公众信任	有效监管有助于建立和维持公众对 AI 技术的信任	过度的负面叙事可能引发不必要的社会恐慌	“AI 末日论”与公众 AI 态度调查

3.2 鼓励开放创新的益处与可能问题

3.2.1 鼓励开放创新的积极价值

加速技术进步与应用落地：开放创新的政策环境鼓励研究者、开发者和企业积极探索 AI 智能体

的技术前沿和应用可能。开源模型的广泛可用性使得全球开发者能够在此基础上构建多样化的智能体应用，形成了丰富的创新生态。Meta 开源的 Llama 系列模型、Mistral AI 的开源模型以及中国深度求索（DeepSeek）的开源大模型，均极大地降低了 AI 智能体的开发门槛，催生了大量创新应用。

促进产业竞争与消费者福利：开放创新环境有利于维持充分的市场竞争，防止少数科技巨头垄断 AI 技术和市场。开源模型的普及使得更多企业能够进入 AI 智能体市场，竞争压力推动产品不断改进和价格下降，最终惠及消费者。Counterpoint Research 的数据显示，2025 年全球 AI 智能体市场中，开源模型驱动的应用占比已超过 35%，且这一比例仍在快速增长[21]。

降低技术准入门槛：开放创新使得中小企业、创业者、研究机构和非营利组织都能够利用先进的 AI 技术解决各自领域的问题，促进了技术的民主化。在发展中国家，开源 AI 模型和低成本部署方案使得本地企业和组织能够开发适合本地语言、文化和需求的 AI 智能体应用，推动数字主权的实现。

推动跨学科和跨界协作：开放创新模式促进了 AI 技术与医学、教育、农业、环保等传统领域的跨界融合。领域专家可以基于开源 AI 模型构建面向特定场景的专业智能体，而不必等待商业公司开发相关产品。这种“长尾创新”模式极大地扩展了 AI 智能体的应用边界和社会价值。

3.2.2 开放创新可能带来的问题

滥用风险的扩散与放大：开放创新的技术门槛降低同样适用于恶意行为者。开源 AI 模型可被用于生成深度伪造内容、开发自动化攻击工具、制造虚假信息等恶意用途。与闭源商业模型不同，开源模型缺乏有效的使用控制和滥用追溯机制。2025 年，安全研究人员发现多个基于开源模型的恶意 AI 智能体在暗网流通，可自动执行网络钓鱼、加密货币诈骗和虚假评论生成。

质量与安全的参差不齐：开放创新环境下涌现的大量 AI 智能体应用质量和安全性良莠不齐。许多应用缺乏基本的安全测试、偏见审计和可靠性验证，但却可能被用于教育、医疗等高风险场景。在缺乏有效质量标识和认证机制的情况下，用户难以区分高质量和低质量的 AI 智能体产品，形成“柠檬市场”（Market for Lemons）效应。

数据与隐私保护的薄弱环节：小型开发者和初创企业往往缺乏足够的资源和专业知識来实施完善的数据保护措施。开放创新生态中大量涌现的 AI 智能体应用可能成为数据泄露和隐私侵犯的薄弱环节。此外，开源模型的微调 and 部署过程中可能引入新的隐私风险，如微调数据的不当处理或模型记忆效应导致的训练数据泄露[22]。

知识产权保护的挑战：开放创新模式与现有知识产权制度之间存在深层张力。AI 模型使用受版权保护的材料进行训练是否构成侵权，目前在全球范围内仍存在激烈争议。2025 年，美国《纽约时报》诉 OpenAI 和微软版权侵权案进入关键审理阶段，判决结果将对 AI 训练数据的版权边界产生深远影响[23]。GitHub Copilot 也因在代码训练中使用开源代码而面临多起集体诉讼。与此同时，AI 智能体生成的内容是否享有版权保护，各国法律立场也存在显著差异。

表 3 鼓励 AI 智能体开放创新的利弊分析

分析维度	积极影响	潜在问题	代表性案例
技术进步	激发多样化创新、 加速技术迭代	技术碎片化、缺乏统一 安全标准	Meta Llama 开源生态
产业竞争	防止垄断、提升 消费者福利	恶性竞争可能压缩 安全投入	DeepSeek 打破闭源 模型价格壁垒
技术民主化	降低使用门槛、	技术滥用门槛同步降低	发展中国家的本地化

	促进数字包容		AI 应用
跨领域创新	促进 AI 与专业领域深度融合	领域专家可能缺乏 AI 安全认知	AI for Science 科研应用
质量保障	开源社区的集体审查提升透明度	"柠檬市场"效应, 劣质应用驱逐优质应用	AI 应用商店的质量参差问题
隐私数据	开源模型的安全性可被独立审计	小开发者数据保护能力不足	第三方安全审计
知识产权	开源精神促进知识共享	训练数据版权侵权争议	NYT 诉 OpenAI 案、GitHub Copilot 案

3.3 寻求平衡：走向"负责任创新"

综合上述分析，本文认为 AI 智能体的治理不应走向"全面放开"或"严加管制"两个极端，而应采纳"负责任创新"（Responsible Innovation）的理念，在促进创新的同时嵌入伦理约束。负责任创新框架包含四个核心维度：预期性（Anticipation）——前瞻性地识别和评估技术可能的社会和伦理影响；反身性（Reflexivity）——开发者、研究者和政策制定者对自身假设和局限性的持续反思；包容性（Inclusion）——将多元利益相关者的声音纳入技术设计和治理过程；响应性（Responsiveness）——根据新信息和反馈及时调整技术方向和治理策略[24]。

在实践层面，本文主张建立"分级分类、动态调适"的治理框架。即根据 AI 智能体的自主程度、应用场景的风险等级和社会影响范围，实施差异化的监管要求（详见第 5 节）。

4. 从计算机伦理角度分析关键伦理问题

本章从计算机伦理学（Computer Ethics）的理论框架出发，结合教材核心概念和章节内容，系统分析 AI 智能体涉及的关键伦理问题。计算机伦理学作为应用伦理学的分支学科，为理解和回应当代信息技术引发的伦理困境提供了系统的分析工具和规范框架。

4.1 IT 职业道德与社会责任

4.1.1 教材核心观点的回顾与概述

计算机伦理学教材系统阐述了 IT 从业人员的职业道德责任。正如教材第 3 章所论述，IT 专业人员承担着超越普通劳动者的特殊社会责任，因为他们的技术决策对社会运行具有广泛而深远的影响。ACM（美国计算机协会）《职业道德与行为准则》提出了"避免伤害他人""尊重隐私""遵守诚信"等核心原则，IEEE-CS/ACM《软件工程职业道德规范》则强调了产品安全、专业胜任和公众利益优先等职业责任。教材进一步指出，IT 职业伦理已从早期的"微观伦理"——关注个体从业者的行为规范——发展为涵盖"宏观伦理"的完整框架，后者关注技术系统的社会性影响和结构性正义问题[25]。

教材第 4 章特别讨论了专业人员的"举报义务"（Whistle-blowing）和"知情同意"责任，指出当技术人员发现系统存在可能危害公众的重大缺陷时，负有超越雇佣关系的更高道德义务。此外，教材还分析了"道德漠视"（Moral Disengagement）的心理机制，即技术人员可能通过责任分散、后果否认、非人化等心理策略回避对自身技术行为的道德反思[26]。

4.1.2 AI 智能体场景下的职业道德分析

AI 智能体的出现对 IT 职业道德提出了新的、更高层次的要求。传统 IT 职业道德侧重于系统可靠性、数据准确性和用户界面友好性等技术性标准，而 AI 智能体时代的职业责任则需要扩展到对系

统自主行为的伦理预判和治理设计。

设计阶段的伦理前置责任：AI 智能体开发者不能将伦理考量视为产品发布后的"补丁"，而应从系统设计之初就嵌入伦理约束。这包括在智能体的目标函数中纳入安全性和公平性考量（如通过 Constitutional AI 和 RLHF 等技术对齐方法），建立智能体行为的"伦理边界"（如拒绝执行可能造成伤害的指令），以及设计"人机闭环"（Human-in-the-Loop）的决策机制。开发者如果忽视这些伦理设计要求，仅追求性能指标和用户增长，则构成了职业伦理的缺失。

测试与部署阶段的尽职责任：在 AI 智能体部署前，开发者和运营者有责任进行充分的安全测试和偏见审计，包括红队测试（Red Teaming）、对抗性测试和不同人口统计群体的公平性评估。特别是在医疗、金融、司法等高风险场景中，应建立独立的第三方审计和认证机制。Anthropic 公司在其 Claude 模型的发布过程中实施的外部红队测试和"负责任的扩展策略"（Responsible Scaling Policy），是这一责任的有益实践[27]。

持续监控与修正的持续责任：与传统软件不同，AI 智能体在部署后的行为可能因环境变化、用户交互和模型更新而发生"漂移"。因此，IT 专业人员的职业道德责任并非在系统上线时终止，而是需要持续监控系统行为、及时发现异常模式、收集用户反馈、并在发现问题时迅速修正或回撤系统。这要求企业建立专门的 AI 安全监控团队和应急响应机制。

拒绝执行的职业判断权：根据 ACM 职业道德准则中的"避免伤害"原则，当 AI 技术人员被要求开发明显违反伦理的 AI 智能体应用时（如用于大规模监控、社会信用评分、自动化武器系统等），他们应享有基于职业良知的拒绝执行权，并应获得相应的法律保护。目前，包括谷歌、微软在内的多家科技巨头的员工已多次通过联名信和抗议活动行使这一权利，如谷歌员工抗议 Project Maven（军用 AI 项目）和 Project Nimbus（以色列政府云计算合同）[28]。



图 1 AI 智能体开发全生命周期的职业道德责任框架

4.2 计算机技术与隐私保护

4.2.1 教材核心观点的回顾与概述

教材第 5 章系统讨论了计算机技术对个人隐私的冲击和隐私保护的理论框架。教材指出，传统隐私概念经历了从"独处权"（The Right to be Let Alone）到"个人信息控制权"的演变。计算机技术的出现使得信息的收集、存储、处理和传播成本急剧下降，个人对其信息的实际控制力大幅减弱。教材分析了数据挖掘、行为追踪、社会网络分析等技术如何使隐私侵犯变得"无形、无感、无处不在"[29]。

教材详细阐述了隐私保护的四个核心原则：（1）知情同意——个人应在充分了解信息收集目的、

范围和使用方式的前提下自主决定；（2）目的限制——个人信息只能用于收集时指定的目的；（3）数据最小化——仅收集和保留实现目的所必需的最少数据；（4）安全保障——采取合理的技术和组织措施保护个人数据安全。此外，教材还讨论了 GDPR 等隐私法规的制度设计，以及隐私增强技术（PETs）如差分隐私、同态加密、联邦学习等技术方案[30]。

教材特别指出了当代隐私问题的两个结构性特征：一是“隐私悖论”（Privacy Paradox）——用户虽然表示关心隐私，但其实际行为往往与之矛盾，部分原因在于服务提供方有意设计的“黑暗模式”（Dark Patterns）使用户难以真正行使隐私选择权；二是“网络效应下的隐私侵蚀”——即使用户自身不使用某项服务，其个人信息也可能因他人的行为和网络关联而被暴露[31]。

4.2.2 AI 智能体场景下的隐私保护分析

AI 智能体的技术特征对隐私保护提出了远超传统计算机系统的挑战。

深度数据访问与隐私边界的消解：为了完成用户指派的任务，AI 智能体通常需要访问远超传统应用的个人数据范围——包括电子邮件内容、私密通信记录、日历安排、文件系统、浏览器历史、位置轨迹、消费记录等。智能体的“工具使用”能力意味着它不仅仅是数据的被动接收者，而是能够主动获取、处理和传输数据的行动者。这种深度的数据访问使得传统的“知情同意”机制面临根本性挑战：用户往往无法在授予权限时充分预见到智能体后续可能如何使用这些数据。

跨上下文数据聚合与推断性隐私侵犯：AI 智能体可能在用户不知情的情况下跨越不同的数据上下文进行关联分析。例如，一个被授权管理用户邮件的智能体可能学习了用户的消费模式、健康状况、社交关系和政治倾向，并在用户未明确授权的情况下将这些推断用于其他任务。这种“推断性隐私”（Inferential Privacy）的侵犯尤为隐蔽，因为推断出的信息可能比原始数据更加敏感，却不受传统隐私框架的充分保护[32]。

间接提示注入与新型隐私攻击：AI 智能体的提示注入（Prompt Injection）漏洞为隐私攻击开辟了全新的途径。攻击者可以通过在智能体可能处理的文档、网页或邮件中嵌入隐藏指令，诱导智能体泄露其已访问的隐私信息。2025 年，一项发表在 USENIX Security 的研究展示了如何通过“多模态间接注入”——将隐藏指令嵌入智能体可能查看的图片中——实现高度隐蔽的隐私窃取[33]。这类攻击的独特性在于，它们利用的不是传统软件的代码漏洞，而是 AI 系统“理解”和“遵从”指令这一核心功能。

“过度代理”与未经授权的隐私行动：AI 智能体可能在用户宽泛授权下，采取用户并未真正期望的行动。例如，用户要求智能体“帮我整理财务文件”，智能体可能理解为将所有财务相关文件打包发送到云端服务进行分析，而这些文件可能包含用户的银行账号、收入证明等高度敏感信息。这种“过度代理”（Over-agency）现象是 AI 智能体特有的隐私风险。

委托隐私与第三方数据共享：AI 智能体的“委托隐私”（Delegated Privacy）问题与传统隐私框架存在深层张力。当用户将隐私相关的决策权交给 AI 智能体（如“帮我判断这封邮件是否安全，拒绝可疑的”），实际上意味着智能体需要“代理”用户的隐私判断。然而，智能体缺乏人类对隐私的上下文敏感性——某些信息在特定关系中是可接受的，但在其他关系中则是不可接受的。这种“隐私代理”的困境目前缺乏有效的技术或制度解决方案[34]。

4.3 信息技术与知识产权问题

4.3.1 教材核心观点的回顾与概述

教材第 6 章系统梳理了信息技术对知识产权制度的挑战。教材指出，知识产权制度的根本目的

是在激励创新与促进知识共享之间取得平衡，而数字技术从多个维度动摇了这一平衡的基础。数字内容的“零边际成本复制”特性使传统以控制复制为核心的知识产权执行机制面临失效。教材讨论了软件版权、软件专利和开源许可三种主要的计算机软件知识产权保护模式，分析了各自的适用场景和局限性。

教材详细讨论了“合理使用”（Fair Use）原则在数字时代的适用挑战，包括四要素检验法——使用的目的和性质、受版权保护作品的性质、使用部分的数量和实质性、使用对作品潜在市场的影响——在软件和大数据场景中的应用困难[35]。教材还分析了数字权利管理（DRM）技术引发的公平使用受限、用户权利侵蚀和互操作障碍等问题，以及开源运动的哲学基础——以理查德·斯托曼（Richard Stallman）的自由软件运动和“Copyleft”理念为代表的替代性知识生产模式[36]。

4.3.2 AI 智能体场景下的知识产权分析

AI 智能体的出现为知识产权领域带来了一系列全新的、高度复杂的问题。

AI 训练数据的版权困境：AI 智能体底层大语言模型的训练使用了海量互联网文本数据，其中包含大量受版权保护的作品。这一做法是否构成版权侵权，目前在全球主要法域均存在争议。在美国，《纽约时报》诉 OpenAI 案的核心争议在于：（1）使用受版权保护的作品进行 AI 训练是否属于“合理使用”；（2）AI 模型是否“记忆”了训练数据中的特定作品内容；（3）模型输出与原始作品内容之间的实质性相似程度。在中国的法律框架下，“文本与数据挖掘”（TDM）的合理使用例外条款正在立法讨论中，目前尚无明确规定[37]。

AI 智能体生成内容的可版权性：AI 智能体在执行任务过程中生成的内容——如报告、代码、设计方案、图片等——是否享有版权保护，以及版权归属于谁，是一个具有重大实践意义的问题。中国版权保护实践目前采取的立场是：完全由 AI 自动生成的、无人类实质性智力贡献的内容不构成作品，不受版权法保护；但有人类创作性选择、编排和修改的 AI 辅助生成内容可以被认定为作品，人类创作者享有版权[38]。美国版权局也采取了类似立场，在 2025 年发布的政策指南中明确要求版权申请者披露 AI 工具的使用情况，并识别出人类作者的创造性贡献部分。

AI 智能体使用第三方工具的版权风险：AI 智能体的工作方式通常是调用各种外部工具和 API。当智能体调用代码生成 API 完成编程任务时，生成的代码可能包含与开源代码实质性相似的部分。如果被调用模型是在包含 GPL 等“传染性”许可代码的数据集上训练的，那么智能体生成的代码是否也受到相应开源许可的约束？这一问题目前缺乏明确的法律判断。GitHub Copilot 因在训练中使用了 GitHub 上的开源代码而面临多起集体诉讼，和解谈判仍在进行中[39]。

AI 自主行为的版权侵权责任归属：当 AI 智能体在自主执行任务时侵犯了他人的知识产权，责任应该由谁承担？例如，如果一个 AI 内容生产智能体自主决定在其生成的文章中使用了他人的版权图片，侵权责任是归于智能体的用户、开发者还是模型提供商？现有版权法的“间接侵权”（Contributory Infringement）和“替代侵权”（Vicarious Liability）理论可以作为分析的起点，但它们能否充分适应 AI 智能体的技术特征仍存在很大争议[40]。

表 4 AI 智能体涉及的关键伦理问题综合分析框架

伦理问题领域	教材核心观点	AI 智能体场景的特殊挑战	利益相关方	现有治理工具
IT 职业道德	公众利益优先、避免伤害 诚实守信、专业胜任	伦理前置设计责任、持续 监控义务、拒绝执行权	开发者、企业 行业组织、监管机构	ACM/IEEE 伦理准则 企业伦理委员会
隐私保护	知情同意、目的限制	深度数据访问、跨上下	用户、开发企业	GDPR、个人信息保护法

	数据最小化、安全保障	文 推断、提示注入攻击 隐私代理困境	第三方服务商 数据保护机构	PETs 技术
知识产权	创新激励与知识共享平衡 合理使用原则	训练数据侵权、生成内容 版权、开源许可传染 责任归属模糊	创作者、AI 企业 用户、开源社区	版权法、开源许可 版权局政策指引
算法公平	算法透明、非歧视 可解释性、程序正义	代理歧视、反馈循环放大 公平性指标的多元冲突	受影响群体、开发者 审计机构	算法影响评估 公平性审计工具
安全与责任	安全设计、风险预防 责任归属、可救济性	幻觉致害、自动化执行 间接提示注入、多手问题	用户、企业 保险公司、法院	责任保险、沙盒测试 红队评估
人机关系	人类自主性、人的尊严 技术异化	过度依赖、技能贬值 人机信任失衡	终端用户、教育机构 用人单位	人机交互设计原则 AI 素养教育

4.4 算法公平与安全责任

4.4.1 算法公平的多维困境

算法公平性并非一个单一、明确的概念，而是包含多种相互竞争的公平性定义和衡量标准。教材第 7 章讨论了算法歧视的多种形态，包括直接歧视、间接歧视和系统性歧视。教材第 9 章（安全篇）从“对抗 AI 犯罪与滥用”的角度讨论了算法歧视的多种形态，包括直接歧视、间接歧视和系统性歧视，并特别警示了 AI 系统将人类偏见“自动化、规模化、隐蔽化”的独特风险。在 AI 智能体场景中，算法公平面临更为复杂的技术和伦理挑战。

公平性度量的不可兼容性：计算机科学的研究已证明，多个常见的公平性指标（如统计均等、机会均等、个体公平）不可能在所有情况下同时满足，除非在极为特殊的条件下[41]。这意味着开发者和监管者必须在不同的公平性观念之间做出选择，而这些选择本质上涉及价值判断，不能仅由技术手段解决。例如，在 AI 信贷审批智能体中，统计均等要求批准率在各群体间相等，这可能意味着对某些群体放宽标准（增加违约风险），而对另一些群体收紧标准（排除可能合格的申请人）。哪种公平性定义更“公正”，取决于社会的价值选择，而非技术参数。

训练数据偏见的代际传递：AI 智能体不仅反映训练数据中的历史偏见，还可能通过部署后的反馈循环将其固化和放大。在招聘场景中，如果历史数据中男性在技术岗位的比例更高，AI 招聘智能体可能将此学习为“偏好信号”，在筛选简历时系统性降低女性申请者的评分，从而导致公司录用更少的女性候选人，进而在下一轮训练数据中进一步强化性别失衡——形成自我实现的歧视循环。

4.4.2 安全风险与多层次防护

AI 智能体的安全风险具有多层次、多向量的特征。除了传统的网络安全威胁（如数据泄露、拒绝服务攻击）外，AI 智能体还面临以下特有的安全挑战，如[图 2](#)：

对齐失败 (Alignment Failure)：即 AI 智能体的行为偏离了设计者和用户的意图和价值观。对齐失败可能表现为目标误设（系统优化了错误的指标）、奖励黑客（系统找到满足形式目标但违背实质意图的方式）和工具性收敛（系统为实现目标而采取不可预见的工具性策略，如自我复制或资源获取）[42]。

对抗性脆弱性：AI 智能体可能对精心设计的对抗性输入产生意外响应。研究发现，在提示中嵌入看似无害的“后缀”可以大幅度改变模型的输出行为；将隐藏指令嵌入智能体可能处理的外部内容中（网页、文档、邮件）可以“劫持”智能体的行为。2025 年，研究人员证明了一种名为“MCP Poisoning”的攻击方式——攻击者在模型上下文协议（MCP）服务器中植入恶意指令，当 AI 智能体连接该 MCP 服务器以扩展能力时，即可被远程操控执行恶意行为[43]。

能力涌现的安全边界模糊：随着模型规模的扩大和架构的改进，AI 智能体可能展现出训练时未明确预期的新能力（能力涌现）。这些涌现能力可能在开发者的安全测试范围之外，构成未被认识到的安全风险。这要求建立持续、动态的安全评估机制，而非仅在发布前进行一次性的安全审计。




图 2 AI 智能体安全威胁的多层次分析

5. 个人观点与案例分析

5.1 未来 AI 智能体伦理治理策略

基于前文的分析，本文提出面向未来的 AI 智能体伦理治理应遵循以下六项核心策略：

5.1.1 建立“分级分类、风险比例”的差异化监管框架

AI 智能体不应被一刀切地监管。本文主张借鉴欧盟 AI 法案的风险分级思路，建立四层分类体系：

禁止级：对社会基本价值和公众安全构成不可接受风险的 AI 智能体应用，如社会信用评分系统、实时远程生物识别监控、潜意识操纵技术、自主武器系统等，应被明确禁止。

高风险级：在医疗诊断、金融交易、司法裁判、招聘录用、教育评价等关键领域部署的 AI 智能体，需接受强制性的第三方合规评估，包括安全审计、偏见检测、可解释性验证和人工监督机制。

有限风险级：直接面向消费者的通用 AI 智能体（如 AI 助手、客服智能体），需满足透明度要

求（明确告知用户正在与 AI 交互）、基本的隐私保护和内容安全标准。

最低风险级：娱乐、游戏、个人非关键用途的 AI 智能体，主要依靠行业自律和用户自我判断，监管干预最小化。

5.1.2 构建"人机共责"的清晰责任链

为解决 AI 智能体的责任归属难题，本文主张建立"链条式+节点式"相结合的复合责任模型：沿 AI 智能体的开发-部署-使用链条，各环节主体在各自控制范围内承担相应责任；模型提供商对模型的基本安全性和已知缺陷负有信息披露和安全设计责任；应用开发者对特定场景的适配安全性、用户提示和权限设计负有直接责任；部署和使用组织对智能体的实际运行监控、员工培训和损害补救负有最终管理责任；在无法明确归因特定方过错的情况下，可借鉴产品责任法中的严格责任原则，由处于最佳风险控制位置的主体（通常为部署者或应用开发者）承担首要赔偿责任，同时设立行业赔偿基金分担极端风险。

5.1.3 推行"透明设计"与"可解释性强制"

AI 智能体的决策过程应具备可审计、可解释和可挑战的特性：高风险领域的 AI 智能体应提供决策的关键影响因素说明和简单的可解释性报告；对个体权益产生重大影响的自动化决策，应保障受影响者的"人工审查请求权"和"有效异议权"；公开 AI 智能体的基本能力指标、已知局限性和独立审计报告，使公众能够在充分知情的情况下做出是否使用和如何使用的判断。

5.1.4 强化"伦理前置"的开发理念

AI 智能体的伦理考量不应是事后补救，而应深度嵌入技术开发的全过程：在需求分析和架构设计阶段即进行伦理影响评估（Ethical Impact Assessment）；在数据收集和处理阶段实施偏见识别和缓解措施；在模型训练和微调阶段采用价值对齐技术（如 RLHF、Constitutional AI 等）；在测试阶段进行全面的红队测试、对抗性测试和公平性审计；在部署阶段设置渐进式灰度发布和安全回滚机制；推广"负责任的扩展策略"（Responsible Scaling Policy），明确不同能力级别对应的安全门槛。



图 3 AI 智能体伦理治理框架示意图

5.1.5 推动"多元共治"的治理生态

AI 智能体的有效治理不能仅依赖政府监管或行业自律，而需要构建政府、企业、学术界、公民社会和公众多方参与、协同互补的治理生态：政府提供法律框架和底线标准；行业组织制定技术标准和最佳实践；学术机构进行独立的安全和伦理研究；公民社会组织代表弱势群体和公众利益参与政策讨论；媒体和公众行使社会监督职能，形成舆论压力；建立常态化的多方利益相关者对话和协商机制，如图3。

5.1.6 加强 AI 伦理教育与公众数字素养

长期的 AI 伦理治理需要从"人"的能力建设入手：将 AI 伦理纳入计算机科学、数据科学和 AI 相关专业的高等教育必修课程；为在职 IT 从业人员提供持续的 AI 伦理培训；在中小学开展面向 AI 时代的数字素养教育，包括批判性评估 AI 输出、识别深度伪造内容、保护个人隐私等核心能力；为政策制定者、法官和执法人员提供 AI 技术和伦理的专门培训。

5.2 代表性案例分析

案例一：加拿大航空 AI 客服错误承诺案

案件背景：2022 年 11 月，加拿大乘客杰克·莫法特（Jake Moffatt）在祖母去世后通过加拿大航空（Air Canada）的网站预订了从温哥华飞往多伦多的全价机票，以便参加葬礼。在购票过程中，莫法特向加拿大航空网站上的 AI 聊天机器人咨询丧亲折扣（Bereavement Fare）政策。AI 客服智能体回复称，乘客可以先购买全价机票，然后在航班出发后 90 天内申请追溯丧亲折扣退款。莫法特依据这一建议购买了机票，票价约为 1,640 加元。

事后，莫法特按照 AI 客服的指引提交了丧亲折扣退款申请，却遭到加拿大航空拒绝。航空公司辩称，其正式的丧亲折扣政策要求在购票前申请，而非购票后追溯申请；AI 客服提供的信息不准确，属于"独立于公司政策之外"的错误，公司不应为此承担责任。莫法特随后向不列颠哥伦比亚省民事解决法庭（Civil Resolution Tribunal）提起诉讼。

裁判结果：2024 年 2 月，法庭做出判决，裁定加拿大航空必须向莫法特支付退款（约 650 加元的差额部分）及诉讼费用。法庭在判决书中指出，加拿大航空对其网站上的所有信息（包括 AI 聊天机器人提供的信息）负有责任。"加拿大航空不能以'AI 独立行动'为由回避其作为服务提供方的注意义务。"法庭进一步指出，企业选择使用 AI 工具来降低客服成本，就必须同时承担该技术带来的错误风险，正如其需要为人类客服的错误负责一样[44]。

伦理分析：本案是"AI 智能体责任归属"问题的标志性案例，涉及多个计算机伦理的核心议题。从职业责任与注意义务角度看，加拿大航空作为服务提供方，对其使用的所有客户沟通渠道（包括 AI 智能体）负有最终的注意义务和监管责任。从计算机伦理角度看，部署 AI 智能体的企业不能简单地将其视为"免责盾牌"。企业有职业道德责任确保其 AI 系统的输出准确、可靠且与公司政策一致。

从人机信任与知情同意角度看，本案揭示了 AI 智能体对用户信任的影响。莫法特合理地信任了航空公司官方渠道（官网聊天机器人）提供的信息，这种信任是任何商业关系的基础。当企业将 AI 智能体嵌入其服务界面时，它在客观上创造了"信息可靠"的合理预期。如果企业允许 AI 提供信息但随后拒绝承担责任，则构成了对用户信任的背弃。

从伦理治理角度看，本案凸显了三个关键需求。第一，企业部署 AI 智能体时应建立充分的前端提示（向用户说明 AI 回答的参考性质）和后端验证机制（定期审计 AI 输出与公司政策的一致性）。第二，法律体系应明确 AI 系统造成损害的归责原则，避免出现"责任真空"。第三，应为 AI 造成的

错误提供明确的救济渠道，不能以“这是 AI 说的”为由拒绝用户合理的维权要求。

案例二：iTutorGroup AI 招聘系统年龄歧视案

案件背景：iTutorGroup 是一家提供在线英语教育服务的跨国公司，在全球范围内招聘在线英语教师。2020 年，该公司部署了一套 AI 自动筛选系统用于处理在线求职申请。该系统被编程为自动拒绝年龄较大的求职者——具体而言，系统设定自动排除 55 岁以上的女性申请者和 60 岁以上的男性申请者。2022 年，美国平等就业机会委员会（EEOC）代表 200 多名因此被自动拒绝的求职者向 iTutorGroup 提起年龄歧视诉讼。EEOC 的调查发现，该公司在 2020 年 3 月至 8 月期间，使用 AI 筛选系统自动拒绝了超过 200 名合格的年长求职者，其中一些求职者拥有数十年的教学经验[45]。

案件结果：2023 年 8 月，iTutorGroup 同意支付 365,000 美元（约合 265 万元人民币）以和解此案。除了经济赔偿外，和解协议还要求该公司停止使用基于年龄的自动筛选功能，并为人力资源人员提供反歧视培训。这是 EEOC 提起的首个涉及 AI 招聘歧视的和解案件，具有里程碑意义。

伦理分析：本案例中算法歧视具有“自动化、规模化、隐蔽化”的系统性特征。与人类个体的偏见不同，AI 招聘系统的歧视可以固化为标准化操作，在数秒内拒绝数百名合格求职者，而每个被拒绝的求职者甚至不知道自己是被“算法”而非“人类”拒绝的。这种歧视的规模和隐蔽性使其社会危害远超传统形式的就业歧视。

从偏见来源看，本案例中的年龄歧视是直接编程的（硬编码规则），但更多情况下，AI 偏见来自训练数据中的历史模式。即使开发者没有明确的歧视意图，AI 系统仍可能通过训练数据反映历史上的就业不平等、特征工程中包含“代理变量”、以及模型在优化预测准确性时过度依赖统计相关性而忽视因果关系。

此案对 AI 智能体伦理治理的启示是多方面的：（1）事前审计的必要性——在部署 AI 招聘智能体之前，应进行强制性的算法偏见审计；（2）透明度保障——求职者应被明确告知 AI 系统在招聘流程中的使用，以及他们有权要求人工审查；（3）持续监控——算法偏见可能随时间漂移，偏见检测应是持续的而非一次性的；（4）人的最终决定权——招聘、晋升、解雇等对个人生计产生重大影响的决策，AI 智能体应仅提供辅助性建议，最终决定权应始终保留在受过反偏见培训的人类决策者手中。

案例三：AI 深度伪造金融诈骗案

案件背景：2024 年 2 月，香港警方披露了一起震惊全球的重大 AI 深度伪造（Deepfake）诈骗案。一家跨国公司的香港分公司财务人员接到了一通看似来自其英国总部 CFO 的视频会议邀请。在视频会议中，除了受害人本人外，其他所有“参会者”——包括 CFO 和其他高级管理人员——均为使用 AI 深度伪造技术生成的虚假形象。诈骗者利用公开可获取的高管照片、视频和音频资料，使用 AI 深度学习技术生成了高度逼真的实时视频和音频，成功冒充公司高层。

在视频会议中，这些“AI 高管”指示该财务人员向指定账户转账，声称这是一项“保密收购交易”。该财务人员因看到和听到“真人”视频而完全相信了指令的真实性，先后进行了 15 次转账，总计汇出 2 亿港元（约合 2,560 万美元）。直至该员工事后通过电话向总部验证，才发现被骗[46]。

案件分析：此案展示了 AI 智能体技术被用于恶意目的的极端危险性。从技术可信度跃升角度看，传统电信诈骗通常依赖文字消息或语音电话，容易引起警惕。而 AI 深度伪造技术将诈骗的“逼真度”提升到了全新水平——受害者不仅听到“声音”，还看到“面孔”，且行为表情自然流畅。这种多模态的逼真伪造使得人类长期以来依赖的“视觉信任”（Seeing is Believing）本能彻底失效。

从信息环境安全角度看，本案暴露了当前信息环境的一个根本性脆弱性：当视频和声音可以被近乎完美地伪造时，远程通信中的身份验证机制面临全面失败。每一位在数字环境中工作的人都需要重新审视“眼见是否为实”这一基本假设。此外，AI 赋能犯罪呈现显著的不对称性：攻击者只需要成功一次即可获得巨额收益，而防御者需要防范每一次攻击。AI 技术大幅降低了高逼真度伪造的成本和技术门槛，使得针对特定目标的“精准诈骗”规模化成为可能。

从治理角度看，此案提示了以下方向：（1）企业需要建立多因素身份验证机制，包括预设的安全口令、区块链时间戳验证等，单纯依赖视频通话不应再被视为安全的身份确认方式；（2）金融机构应建立大额转账的多重确认流程和“冷静期”机制；（3）平台和工具开发者应开发更强大的深度伪造检测技术，并降低使用门槛；（4）法律执行机构需要建立跨国 AI 犯罪的快速协作机制。

表 5 代表性 AI 智能体伦理案例对比分析

分析维度	加拿大航空 AI 客服案	iTutorGroup AI 招聘歧视案	AI 深度伪造金融诈骗案
发生时间	2022-2024 年	2020-2023 年	2024 年
涉及领域	消费者服务	就业与招聘	金融安全
核心伦理问题	AI 责任归属、企业注意义务 用户信任	算法歧视、就业公平 自动化决策	技术恶意滥用、身份认证安全 跨国犯罪
AI 角色	面向消费者的 AI 客服智能体	后台自动筛选 AI 系统	恶意 AI 深度伪造技术
损害后果	消费者经济损失 (约 650 加元)	200+名年长求职者 被歧视性拒聘	企业经济损失 2 亿港元
法律处理	法庭判决企业承担责任	EEOC 起诉后以 36.5 万美元和解	香港警方立案调查 追回部分资金
核心教训	部署者应对 AI 行为负责	AI 可系统化放大歧视	深度伪造突破身份认证底线
治理启示	明确 AI 责任链 建立用户救济渠道	强制偏见审计 保障人的最终决定权	多因素验证、跨国协作 检测技术研发

6. 结论

AI 智能体作为人工智能技术发展的新范式，正以前所未有的速度和广度渗透到社会经济的各个领域。它既代表了巨大的社会进步潜力——提高效率、降低成本、促进公平、赋能个体，也带来了深刻的伦理挑战——错误决策、隐私侵蚀、责任真空、算法歧视和安全威胁。本文从计算机伦理学的理论视角出发，结合具体应用场景和真实案例，对 AI 智能体的伦理风险和治理策略进行了系统分析。

本文的核心主张可以概括为以下几点：

第一，AI 智能体的伦理问题不能简单地归入传统的技术伦理或职业伦理范畴，而需要在新的技术社会条件下进行创造性回应。智能体的自主性、行动能力和广泛的代理权使其伦理影响远超此前任何信息技术系统。

第二，监管与创新之间并非零和博弈。“负责任创新”的理念为二者提供了兼容的路径——将伦理考量嵌入创新过程，而非在创新之后追加约束。分级分类、风险比例的监管框架可以在保护公共安全的同时，为低风险创新保留充足的空间。

第三，AI 智能体的责任归属需要超越传统的“过错-因果”模式，建立更加复杂但更加公平的复合责任体系。模型提供商、应用开发者、部署企业和终端用户应在各自的控制范围内承担相应责任，同时社会层面的风险分担机制（如保险、赔偿基金）也是必要的补充。

第四，有效的 AI 智能体治理需要多元主体的协同参与。单靠政府监管、行业自律或技术创新均不足以应对这一复杂挑战。需要构建制度约束、技术方案、行业标准、公众教育和社会监督五位一体的治理生态。

第五，AI 伦理治理的根本目标不仅是“防止坏事发生”，而是“引导好事发生”。伦理不应被理解为对技术发展的否定和阻碍，而应被理解为确保技术发展真正服务于人类福祉的必要保障。一个缺乏伦理约束的 AI 智能体生态可能在短期内繁荣，但从长远看将因公众信任的流失而难以为继。

面向未来，AI 智能体技术将继续快速发展，新的能力和应用场景将不断涌现，伦理挑战也将持续演化。本文提出的“分级分类、人机共责、透明可溯、多元共治、动态迭代”治理策略只是一个起点。AI 智能体的伦理治理是一项需要持续学习、不断调整和多方协作的长期事业。技术开发者、政策制定者、学术研究者和每一位受技术影响的公民，都应成为这一事业的积极参与者。

参考文献

- [1] Wooldridge, M., & Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2), 115-152.
- [2] MarketsandMarkets. (2025). AI Agents Market – Global Forecast to 2030. Market Research Report.
- [3] 国务院办公厅. (2025). 国务院 2025 年度立法工作计划. 国办发〔2025〕12 号.
- [4] Wang, L., Ma, C., Feng, X., et al. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6), 186345.
- [5] Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). The impact of AI on developer productivity: Evidence from GitHub Copilot. arXiv preprint, arXiv:2302.06590.
- [6] McKinsey Global Institute. (2023). The economic potential of generative AI: The next productivity frontier. McKinsey & Company.
- [7] 中国信息通信研究院. (2025). 人工智能发展报告（2025 年）. 中国信通院.
- [8] Weiser, B. (2023). Here's what happens when your lawyer uses ChatGPT. *The New York Times*, May 27, 2023.
- [9] Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec '23)*, 79-90.
- [10] Nissenbaum, H. (1996). Accountability in a computerized society. *Science and Engineering Ethics*, 2(1), 25-42.
- [11] Civil Resolution Tribunal of British Columbia. (2024). *Moffatt v. Air Canada*, 2024 BCCRT 149.
- [12] World Economic Forum. (2025). The Future of Jobs Report 2025. World Economic Forum, Geneva.
- [13] Blease, C., Kaptchuk, T. J., Bernstein, M. H., Mandl, K. D., Halamka, J. D., & DesRoches, C. M. (2024). Artificial intelligence and the future of primary care. *Journal of Medical Internet Research*, 26(1), e12345.
- [14] Raghavan, M., Barocas, S., Kleinberg, J., & Levy, K. (2020). Mitigating bias in algorithmic hiring: Evaluating claims and practices. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAccT '20)*, 469-481.
- [15] O'Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown Publishing Group.
- [16] Europol. (2025). AI-Powered Crime: Threat Assessment 2025. European Union Agency for Law Enforcement Cooperation.

- [17] European Parliament and Council. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). Official Journal of the European Union.
- [18] 国家互联网信息办公室等七部门. (2023). 生成式人工智能服务管理暂行办法. 2023 年 8 月 15 日起施行.
- [19] Chee, F. Y., & Coulter, M. (2023). European companies slam EU AI Act for stifling innovation. Reuters, June 30, 2023.
- [20] Janz, J., & Gemünden, H. G. (2022). The impact of GDPR on European startup innovation and investment. *Research Policy*, 51(8), 104561.
- [21] Counterpoint Research. (2025). Global AI Agent Market Share and Forecast, Q1 2025. Industry Report.
- [22] Carlini, N., Tramer, F., Wallace, E., et al. (2021). Extracting training data from large language models. 30th USENIX Security Symposium (USENIX Security '21), 2633–2650.
- [23] The New York Times Company v. Microsoft Corporation and OpenAI, Inc. (2023). Case 1:23-cv-11195, United States District Court for the Southern District of New York.
- [24] Stilgoe, J., Owen, R., & Macnaghten, P. (2013). Developing a framework for responsible innovation. *Research Policy*, 42(9), 1568–1580.
- [25] Association for Computing Machinery (ACM). (2018). ACM Code of Ethics and Professional Conduct. ACM.
- [26] Bandura, A. (2002). Selective moral disengagement in the exercise of moral agency. *Journal of Moral Education*, 31(2), 101–119.
- [27] Anthropic. (2024). Anthropic's Responsible Scaling Policy. Anthropic PBC.
- [28] Shane, S., & Wakabayashi, D. (2018). 'The business of war': Google employees protest work for the Pentagon. *The New York Times*, April 4, 2018.
- [29] Solove, D. J. (2008). *Understanding Privacy*. Harvard University Press.
- [30] 全国人民代表大会常务委员会. (2021). 中华人民共和国个人信息保护法. 2021 年 11 月 1 日起施行.
- [31] Acquisti, A., Brandimarte, L., & Loewenstein, G. (2015). Privacy and human behavior in the age of information. *Science*, 347(6221), 509–514.
- [32] Wachter, S., & Mittelstadt, B. (2019). A right to reasonable inferences: Re-thinking data protection law in the age of big data and AI. *Columbia Business Law Review*, 2019(2), 494–620.
- [33] Liu, Y., Deng, G., Li, Y., et al. (2025). Multimodal indirect prompt injection attacks against vision-language agents. 34th USENIX Security Symposium (USENIX Security '25).
- [34] Bartneck, C., Lüdtge, C., Wagner, A., & Welsh, S. (2021). *An Introduction to Ethics in Robotics and AI*. Springer.
- [35] Samuelson, P. (2015). Freedom to tinker: The uncertain future of fair use in the digital age. *Theoretical Inquiries in Law*, 17(1), 57–92.
- [36] Stallman, R. M. (2002). *Free Software, Free Society: Selected Essays of Richard M. Stallman*. GNU Press.
- [37] 国家版权局. (2024). 人工智能生成内容著作权保护指导意见 (征求意见稿) .
- [38] 北京互联网法院. (2023). (2023)京 0491 民初 11280 号民事判决书 ("AI 文生图第一案") .
- [39] *DOE 1 et al v. GitHub, Inc. et al.* (2022). Case 4:22-cv-06823, United States District Court for the Northern District of California.
- [40] Lemley, M. A., & Casey, B. (2021). Fair learning. *Texas Law Review*, 99(4), 743–785.
- [41] Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. *Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS '17)*, 43:1–43:23.
- [42] Ngo, R., Chan, L., & Mindermann, S. (2024). The alignment problem from a deep learning perspective. *Proceedings of the 41st International Conference on Machine Learning (ICML '24)*.

- [43] 奇安信技术研究院. (2025). 2025 年 AI 安全威胁态势报告. 奇安信集团.
- [44] Moffatt v. Air Canada. (2024). Civil Resolution Tribunal of British Columbia, 2024 BCCRT 149.
- [45] Equal Employment Opportunity Commission v. iTutorGroup, Inc. et al. (2022). Case 1:22-cv-02565, United States District Court for the Eastern District of New York.
- [46] 香港警务处. (2024). 科技罪案简报 (2024 年第一季度) . 香港警务处网络安全及科技罪案调查科.
- [47] Floridi, L., & Cowls, J. (2019). A unified framework of five principles for AI in society. Harvard Data Science Review, 1(1).
- [48] 中国电子技术标准化研究院. (2025). 人工智能伦理治理标准化白皮书 (2025 版) .
- [49] Russell, S. (2019). Human Compatible: Artificial Intelligence and the Problem of Control. Viking.
- [50] Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. Nature Machine Intelligence, 1(9), 389-399.

附录：AI 工具使用说明

本报告在研究和写作过程中使用了以下 AI 工具进行辅助：

1. 文献检索与整理：使用 AI 辅助检索和整理中英文学术文献、新闻报道和政策文件，提高了文献收集的效率。
2. 内容组织与草稿生成：使用 AI 辅助进行论文结构设计、段落组织和初稿撰写，在此基础上进行了大量的人工修改、补充和完善。
3. 案例资料整理：使用 AI 辅助整理案例的事实背景和时间线，核心分析和观点由作者独立完成。
4. 格式与排版辅助：使用 AI 辅助进行参考文献格式的统一和排版优化。