



线性判别分析(LDA)

 课程名称：机器学习

 章节：第3章 线性判别分析

 授课人：魏军

分类问题回顾

📖 核心定义


根据输入的特征向量，预测其所属的离散类别，是机器学习的核心任务之一

📋 典型场景

- 垃圾邮件识别：区分“垃圾”与“正常”邮件
- 图像分类：识别图片主体是“猫”还是“狗”
- 疾病诊断：根据指标判断是否患病

🎯 核心挑战

寻找最优的决策边界，有效分离不同类别样本，同时保证分类的准确性



二维平面上的分类决策边界示意

PCA内容回顾



数据降维

- 把高维特征压缩成少数几个主成分
- 减少计算量、加速模型训练、降低过拟合风险




特征抽取

- 重新组合出有代表性的新特征
- 保留主要信息，过滤噪声信息




可视化

把高维数据降到 2D/3D，画成散点图直观观察分布、聚类、异常点



PCA降维示意图


PCA如何用于分类？




- 高维数据 → 标准化 → PCA降维 → 低维数据 → 分类器训练 → 预测 → 评估结果
- PCA为无监督降维方法，**单独无法完成分类，需与分类器结合**，实现先降维后分类

PCA用于分类面临的问题

2维降到1维



3维降到2维



- PCA以方差最大为目标降维，不一定保留对分类最关键的信息，导致分类效果下降
- PCA和分类器各自为战，缺乏协同，无法实现特征提取与分类任务的联合最优

如何构建面向分类任务的降维方法？

📖 方案1: PCA投影降维

$$\max w^T S w \quad s.t. \quad w^T w = 1$$


📊 优化结果

$$S = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T = \frac{1}{n} X X^T$$

w 是 S 最大特征值对应的特征向量

🎯 存在问题

- 沿着方差最大的方向投影
- 蓝色和红色的点存在大量重叠



不同投影方案示意图

如何构建面向分类任务的降维方法？

📖 方案2：最大化投影后两类的距离

$$\max ||w^T \mu_1 - w^T \mu_2|| \quad s.t. \quad w^T w = 1$$


📊 优化结果

$$w^T (\mu_1 - \mu_2)$$

当 w 与 $(\mu_1 - \mu_2)$ 方向一致的时候，该距离最大



🎯 存在问题

- 较好的区分出了蓝色和红色点
- 但仍然存在少量重叠区域
- 没有考虑每类数据的分布形态



不同投影方案示意图

如何构建面向分类任务的降维方法？



方案3：同时考虑投影后每类的均值和方差

- 均值确定大概的投影方向
- 方差对投影方向进行微调

线性判别分析 (LDA)

📖 方法定位：有监督学习

经典的线性降维与分类方法，训练过程依赖样本的类别标签信息，区别于无监督的**PCA**

📐 核心思想：投影与分离


通过线性变换将高维数据投影至低维空间，使同类样本聚集，不同类样本分离

🎯 核心目标：最优投影方向

寻找一组最优的投影向量，最大化类别间的可分性，为后续的分类任务奠定基础

数据空间 / UMRDACE

三维空间的与种类点...被投影到1D投影，按实现了更好的分离效果




三维数据点投影至一维直线实现分离


- LDA全称：**Linear Discriminant Analysis**
- 1936 年，统计学家 Ronald A. Fisher 在论文《The Use of Multiple Measurements in Taxonomic Problems》中首次提出 **Fisher 线性判别**，用于解决二分类问题

线性判别分析 (LDA)

1. 寻找最优视角 (Search Space)
当前角度 $\theta = 0.0^\circ$



2. 投影结果 (Scalar Space)
Fisher Score $J(w) = 4.50$



LDA和PCA的区别

目标不同

- **PCA**: 从协方差角度考虑, 使得投影后方差最大
- **LDA**: 从标签角度考虑, 使得投影后不同类别在投影方向上尽可能分开, 同一类别内部尽可能紧凑

监督不同

- **PCA**: 无监督降维方法
- **LDA**: 有监督降维方法

LDA优化目标

- 投影后, 类间距离尽量大
- 投影后, 类内距离尽量小

LDA 数学推导

二分类LDA的基本设定

假设有两类样本，每个样本都是 d 维向量 $x \in \mathbb{R}^d$

✓ 第1类: $\mathcal{C}_1$, 样本数 n_1

✓ 第2类: $\mathcal{C}_2$, 样本数 n_2

希望找一个投影方向 $w \in \mathbb{R}^d$, 把样本投影到一维:


$$y = w^T x$$

✓ 第1类均值变成 $w^T \mu_1$

✓ 第2类均值变成 $w^T \mu_2$

其中原空间中两类均值分别为:

$$\mu_1 = \frac{1}{n_1} \sum_{x \in \mathcal{C}_1} x, \quad \mu_2 = \frac{1}{n_2} \sum_{x \in \mathcal{C}_2} x$$



计算类间离散度

投影后两类中心距离应尽可能大：

$$m_1 = w^T \mu_1, \quad m_2 = w^T \mu_2$$

类间散度定义为：


$$||m_1 - m_2||^2$$

代入得：

$$||w^T \mu_1 - w^T \mu_2||^2$$

展开得：

$$(w^T \mu_1 - w^T \mu_2)(w^T \mu_1 - w^T \mu_2)^T$$



计算类间离散度

$$(w^T \mu_1 - w^T \mu_2)(w^T \mu_1 - w^T \mu_2)^T$$

写成矩阵形式：


$$w^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w$$

因此定义**类间散度矩阵**：

$$S_b = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

于是：

$$w^T S_b w$$



计算类内离散度


希望每一类内部投影后尽量集中

第1类投影后的方差：

$$\text{Var}(\mathcal{C}_1) = \sum_{x \in \mathcal{C}_1} (w^T x - w^T \mu_1)^2$$

$$\text{Var}(\mathcal{C}_1) = \frac{1}{n_1} \sum_{x \in \mathcal{C}_1} w^T (x - \mu_1)(x - \mu_1)^T w = w^T S_1 w$$

$$S_1 = \frac{1}{n_1} \sum_{x \in \mathcal{C}_1} (x - \mu_1)(x - \mu_1)^T$$



计算类内离散度

同理

$$\text{Var}(\mathcal{C}_2) = \frac{1}{n_2} \sum_{x \in \mathcal{C}_2} w^T (x - \mu_2)(x - \mu_2)^T w = w^T S_2 w$$


$$S_2 = \frac{1}{n_2} \sum_{x \in \mathcal{C}_2} (x - \mu_2)(x - \mu_2)^T$$

记作

$$S_w = S_1 + S_2$$

投影后的总类内离散度：

$$\text{Var}(\mathcal{C}_1) + \text{Var}(\mathcal{C}_2) = w^T S_1 w + w^T S_2 w = w^T S_w w$$



Fisher判别准则

优化目标


$$\max w^T S_b w$$

$$\min w^T S_w w$$

单独约束会互相冲突，如何组合？

$$\max w^T S_b w - w^T S_w w$$

对 w 尺度敏感



Fisher判别准则

于是 LDA 就要最大化下面这个比值：


$$J(w) = \frac{w^T S_b w}{w^T S_w w}$$

这就是经典的 **Fisher判别准则**。

含义很直接：

- ✓ 分子大：类间分离大
- ✓ 分母小：类内紧凑

对w尺度不敏感



求解优化

$$J(w) = \frac{w^T S_b w}{w^T S_w w}$$

由于 $J(w)$ 与 w 的尺度无关，可以固定分母：


$$w^T S_w w = c$$

于是问题变成：

$$\max w^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w$$

构造拉格朗日函数：

$$\mathcal{L} = w^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w - \lambda (w^T S_w w - c)$$



求解优化

$$\mathcal{L} = w^T(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w - \lambda(w^T S_w w - c)$$

$$\frac{\partial \mathcal{L}}{\partial w} = 2(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w - 2\lambda S_w w = 0$$


$$(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w = \lambda S_w w$$

$$S_w^{-1}(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w = \lambda w$$

可知最优解方向与 $S_w^{-1}(\mu_1 - \mu_2)$ 同方向，因此：

$$w \propto S_w^{-1}(\mu_1 - \mu_2)$$

这就是二分类LDA最核心的结论。




计算结果分析

$$w = S_w^{-1}(\mu_1 - \mu_2)$$

可以分两部分看：

- ✓ $\mu_1 - \mu_2$ ：表示两类中心连线方向，告诉我们“应该朝哪里分”
- ✓ S_w^{-1} ：对类内散度进行校正，抑制类内波动大的方向

所以它不是简单沿着均值差方向投影，而是考虑了各方向上的噪声和重叠程度。



LDA计算步骤总结

假设训练集已经给定，计算流程如下：

第一步：计算每一类均值

$$\mu_1 = \frac{1}{n_1} \sum_{x \in \mathcal{C}_1} x, \quad \mu_2 = \frac{1}{n_2} \sum_{x \in \mathcal{C}_2} x$$

第二步：计算每一类的类内散度矩阵

$$S_1 = \frac{1}{n_1} \sum_{x \in \mathcal{C}_1} (x - \mu_1)(x - \mu_1)^T, \quad S_2 = \frac{1}{n_2} \sum_{x \in \mathcal{C}_2} (x - \mu_2)(x - \mu_2)^T$$

第三步：求总类内散度矩阵

$$S_w = S_1 + S_2$$

第四步：求投影方向

$$w = S_w^{-1}(\mu_1 - \mu_2)$$


第五步：将样本投影

$$y = w^T x$$

第六步：确定分类阈值

最简单可取两个投影均值的中点： $t = \frac{w^T \mu_1 + w^T \mu_2}{2}$

若 $w^T x > t$ ，则判为某一类，否则判为另一类。



LDA vs PCA：核心区别对比

特性维度	LDA (线性判别分析)	PCA (主成分分析)
监督性	有监督学习，利用类别标签信息	无监督学习，不利用任何标签信息
核心目标	最大化类间可分性（类间散度/类内散度）	最大化数据的总方差，保留最多信息
主要用途	分类任务前的特征降维、特征提取	通用的数据降维、可视化、去噪
数据关注点	关注数据的类别区分能力	关注数据的全局结构和方差分布
降维维度限制	最多可降至 (类别数 - 1) 维	无理论维度限制，可降至任意维度