



逻辑回归

Logistic Regression

 课程名称：机器学习

 章节：第5章 逻辑回归

 授课人：魏军

监督学习概念

回归 (Regression)

- 如何预测上海浦东的房价?
- 未来的股票市场走向?

标签连续

分类 (Classification)

- 身高1.85m, 体重100kg的男人穿什么尺码的T恤?
- 根据肿瘤的体积、患者的年龄来判断良性或恶性?


标签离散

监督学习分为回归和分类

分类任务介绍 文本

将文本划分为不同的类别

垃圾邮件过滤



情感识别

Review (X)

"This movie is fantastic! I really like it because it is so good!"

"Not to my taste, will skip and watch another movie"

"This movie really sucks! Can I get my money back please?"

Rating (Y)



文章打标签




舆情分析

分类任务介绍

图
象

将图象划分为不同的类别



CIFAR 10



MNIST

分类任务介绍


定义

给定

- 样本空间 $\mathbb{X}$ 中一个样本 x ($x \in \mathbb{X}$)的描述
- 一个固定的类别集: $C = \{c_1, c_2, \dots, c_m\}$


求解

- x 的类别: $f(x) \in C$, 其中 $f(x)$ 是一个定义域为 $\mathbb{X}$, 值域为 C 的类别函数




分类任务介绍

线性 VS 非线性



线性可分



线性不可分

线性可分性：是否存在 $ax_1 + bx_2 + c = 0$

使得对于所有的正例： $ax_1 + bx_2 + c > 0$

对于所有的负例： $ax_1 + bx_2 + c < 0$

二分类逻辑回归

线性回归模型

回顾

如何将线性回归模型改造为分类模型？

线性回归试图学得一个线性函数以尽可能准确地预测 y ，假设线性函数如下

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

函数 $h_{\theta}(x)$ 表示以 θ 为参数， $\theta_0, \theta_1, \theta_2, \dots, \theta_n$ 是回归参数（待求解），上式可改写成


$$h_{\theta}(x) = \sum_{j=0}^n \theta_j x_j = \theta^T x$$

其中 $h_{\theta}(x) \in [-\infty, +\infty]$ ，而分类预测结果需要得到 $[0, 1]$ 的概率值

逻辑回归模型

生物学启发



单个神经细胞只有两种状态：兴奋和抑制



逻辑回归模型

人工神经元

模拟生物神经元，具有权重、偏置及激活函数，输出为+1或-1，无法比较不同样本离分类边界的远近




逻辑回归模型

Sigmoid函数

线性回归输出是任意实数: $z = \theta^T x$

但做二分类问题时, 希望输出一个0~1 之间的概率值, 表示“属于正类的可能性”



$$\sigma(z) = \frac{1}{1+e^{-z}}$$

- 输入一个 $[-\infty, +\infty]$ 的值, 输出一个概率值
- 当 $z \rightarrow +\infty$ 时, $\sigma(z) \rightarrow 1$, 非常像正类
- 当 $z = 0$ 时, $\sigma(z) = 0.5$, 类别不确定
- 当 $z \rightarrow -\infty$ 时, $\sigma(z) \rightarrow 0$, 非常像负类

逻辑回归模型

形式定义

将线性预测 $\theta^\top x$ 代入Sigmoid函数得到概率估计 p

- 正类的概率 $p(y = 1|x) = \frac{1}{1 + e^{-\theta^\top x}}$
- 负类的概率 $p(y = 0|x) = 1 - \frac{1}{1 + e^{-\theta^\top x}}$

设置阈值 h 决定样本最终分类结果

$$\hat{y} = \begin{cases} 1, & p_\theta(y = 1|x) > h \\ 0, & \text{otherwise} \end{cases}$$

损失函数推导

伯努利分布

伯努利分布，又名两点分布或者0-1分布，随机变量 X 只有两种取值 $\{0, 1\}$

- 若试验**成功**，则随机变量 X 取值为 $x = 1$ ，记其概率为 $P(X = 1) = p$
- 若试验**失败**，则随机变量 X 取值为 $x = 0$ ，记其概率为 $P(X = 0) = 1 - p$

$$P(X = x) = p^x (1 - p)^{1-x}$$

逻辑回归，给定输入样本 x 输出结果 y 只有两种取值 $\{0, 1\}$

- 若为**正类**，则输出结果取值为 $y = 1$ ，记其概率为 $P(y = 1|x) = p$
- 若为**反类**，则输出结果取值为 $y = 0$ ，记其概率为 $P(y = 0|x) = 1 - p$

$$P(y|x) = p^y (1 - p)^{1-y}$$



损失函数推导

极大似然估计

问题设定

- 样本数据: $x_1, x_2, \dots, x_n$
- 假设数据来自某个分布: $p(x | \theta)$
- 目标: 找一组参数 θ , 让已观测数据 “最有可能出现”

写出似然函数

把概率模型变成关于参数的函数, 假设样本独立同分布, 则联合概率为 $L(\theta) = \prod_{i=1}^n p(x_i | \theta)$

取对数似然

因为连乘不好求导, 所以取对数 $\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i | \theta)$

求导并令其为 0

计算极值点对应的 θ , 得到最终解 $\frac{\partial \ell(\theta)}{\partial \theta} = 0$

损失函数推导

极大似然估计

举例

抛掷质地均匀的硬币，正面朝上和反面朝上的概率是否相等

方法一：主观判断

- 既然质地均匀那必然相等

方法二：实践检验

- 准备一枚均匀的硬币
- 将硬币抛起，使其在空中旋转并自然落下
- 记录每次抛掷的结果(正面朝上或反面朝上)
- 重复多次，统计正面和反面的出现次数

抛掷次数	正面朝上 (次)	反面朝上 (次)	正面频率	反面频率
10	6	4	0.60	0.40
20	11	9	0.55	0.45
30	16	14	0.53	0.47
40	21	19	0.53	0.48
50	26	24	0.52	0.48
60	31	29	0.52	0.48
70	36	34	0.51	0.49
80	41	39	0.51	0.49
90	46	44	0.51	0.49
100	51	49	0.51	0.49

在大量重复试验中，正面朝上和反面朝上的频率近似相等

概率 = 频率？

损失函数推导

极大似然估计

举例

抛掷质地均匀的硬币，正面朝上和反面朝上的概率是否相等

方法三：理论推导

- 正面记为 $x = 1$ ，其朝上概率为 p
- 反面记为 $x = 0$ ，其朝上概率为 $1 - p$
- 似然函数：

$$L(p) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$

- 对数似然：

$$\ell(p) = \left(\sum_{i=1}^n x_i \right) \log p + \left(n - \sum_{i=1}^n x_i \right) \log(1 - p)$$

- 求导并令 0：

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$$



正面朝上的概率 **等于** 正面出现的频率

损失函数推导

极大似然估计

逻辑回归预测概率:

$$P(y|x) = p^y (1 - p)^{1-y}$$

假设有 m 个样本, 则似然函数为:

$$L(\theta) = \prod_{i=1}^m P(y^{(i)}|x^{(i)}) = \prod_{i=1}^m (p(x^{(i)}))^{y^{(i)}} (1 - p(x^{(i)}))^{1-y^{(i)}}$$

似然函数两边取对数, 则连乘号变成了连加号:

$$l(\theta) = \log L(\theta) = \sum_{i=1}^m (y^{(i)} \log(p(x^{(i)})) + (1 - y^{(i)}) \log(1 - p(x^{(i)})))$$

最大化

损失函数为:

$$J(\theta) = -\frac{1}{m} l(\theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(p(x^{(i)})) + (1 - y^{(i)}) \log(1 - p(x^{(i)})))$$

最小化

为了衡量算法在全部训练样本上的表现如何, 我们需要定义一个算法的损失函数, 算法的损失函数是对 m 个样本的损失函数求和然后除以 m

损失函数推导

二值交叉熵

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(p(x^{(i)})) + (1 - y^{(i)}) \log(1 - p(x^{(i)})))$$

$$\mathcal{L}(y, x) = -y \log p_{\theta} - (1 - y) \log(1 - p_{\theta})$$

$$y = 1, \quad L = -\log(p_{\theta})$$

$$y = 0, \quad L = -\log(1 - p_{\theta})$$

	Class 1	Class 2
真实值	0	1
预测值	0.3	0.7

在给定 y 的情况下，如果 p 和 y 越接近，交叉熵越小；如果 p 和 y 越远，交叉熵就越大。

逻辑回归求解

Sigmoid 求导

导数只和自身有关，计算非常方便，这是能用梯度下降训练逻辑回归的关键

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma'(z) = \left(\frac{1}{1 + e^{-z}} \right)' = \frac{e^{-z}}{(1 + e^{-z})^2}$$

$$\sigma'(z) = \left(\frac{1}{1 + e^{-z}} \right)' = \frac{(1 + e^{-z}) - 1}{(1 + e^{-z})^2}$$

$$\sigma'(z) = \left(\frac{1}{1 + e^{-z}} \right)' = \frac{1}{(1 + e^{-z})} \left(1 - \frac{1}{(1 + e^{-z})} \right)$$

$$\sigma'(z) = \left(\frac{1}{1 + e^{-z}} \right)' = \sigma(z)(1 - \sigma(z))$$

逻辑回归求解

Sigmoid 求导

$$\mathcal{L}(y, x) = -y \log \sigma(x) - (1 - y) \log(1 - \sigma(x))$$

$$\begin{aligned} \frac{\partial \mathcal{L}(y, x, p_\theta)}{\partial \theta} &= -y \frac{1}{\sigma(x)} \sigma(x)(1 - \sigma(x))x - (1 - y) \frac{-1}{1 - \sigma(x)} \sigma(x)(1 - \sigma(x))x \\ &= (\sigma(x) - y)x \end{aligned}$$

逻辑回归求解

$$J(w) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(\sigma(x^{(i)})) + (1 - y^{(i)}) \log(1 - \sigma(x^{(i)})))$$

$$\frac{\partial}{\partial w_j} J(w) = \frac{1}{m} \sum_{i=1}^m (\sigma(x^{(i)}) - y^{(i)}) x_j^{(i)}$$


$$w_j = w_j - \alpha \frac{\partial J(w)}{\partial w} = w_j - \alpha \frac{1}{m} \sum_{i=1}^m (\sigma(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

逻辑回归求解


引入正则化防止过拟合

当 λ 的值开始上升时，降低了方差。


$$J(w) = \frac{1}{m} \sum_{i=1}^m \left[-y^{(i)} \log(\sigma(x^{(i)})) - (1 - y^{(i)}) \log(1 - \sigma(x^{(i)})) \right] + \underbrace{\frac{\lambda}{2m} \sum_{j=1}^n w_j^2}_{\text{正则化项}}$$



没有正则化，过拟合




正则化过度，欠拟合



适当的正则化

Cost



多分类逻辑回归

逻辑回归模型

二分类 VS 多分类

二分类逻辑回归只能判别“是”和“非”，无法区分多个类别



葡萄



蓝莓



柠檬



菠萝



橄榄



覆盘子



无花果



百香果



椰子肉


水果分类 (9类)

0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	2	2	2	2	2	2	2	2	2	2	2	2	2	2
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3
4	4	4	4	4	4	4	4	4	4	4	4	4	4	4
5	5	5	5	5	5	5	5	5	5	5	5	5	5	5
6	6	6	6	6	6	6	6	6	6	6	6	6	6	6
7	7	7	7	7	7	7	7	7	7	7	7	7	7	7
8	8	8	8	8	8	8	8	8	8	8	8	8	8	8
9	9	9	9	9	9	9	9	9	9	9	9	9	9	9

数字分类 (10类)


逻辑回归模型

二分类 VS 多分类



二分类逻辑回归

- 正类的概率 $p(y = 1|x) = \frac{1}{1 + e^{-\theta^T x}}$
- 负类的概率 $p(y = 0|x) = 1 - \frac{1}{1 + e^{-\theta^T x}}$




多分类逻辑回归

- 类1的概率 $p(y = 1|x) = ?$
- 类2的概率 $p(y = 2|x) = ?$
- 类3的概率 $p(y = 3|x) = ?$

逻辑回归模型

二分类模型

视角1：二分类逻辑回归本质是比较 $\theta^T x$ 的值和 0 的大小




二分类逻辑回归

- 正类的概率 $p(y = 1|x) = \frac{1}{1 + e^{-\theta^T x}} = \frac{e^{\theta^T x}}{e^{\theta^T x} + 1} = \frac{e^{\theta^T x}}{e^{\theta^T x} + e^0}$
- 负类的概率 $p(y = 0|x) = 1 - \frac{1}{1 + e^{-\theta^T x}} = \frac{1}{e^{\theta^T x} + 1} = \frac{e^0}{e^{\theta^T x} + e^0}$
- 二分类逻辑回归比较正类和负类的概率大小得到预测类别

逻辑回归模型

二分类模型

视角2：二分类逻辑回归本质是比较正类 $\theta_1^T x$ 和负类回归 $\theta_0^T x$ 的大小




- 正类的概率 $p(y = 1|x) = \frac{e^{\theta_1^T x}}{e^{\theta_1^T x} + e^{\theta_0^T x}} = \frac{e^{(\theta_1 - \theta_0)^T x}}{e^{(\theta_1 - \theta_0)^T x} + e^0}$
- 负类的概率 $p(y = 0|x) = \frac{e^{\theta_0^T x}}{e^{\theta_1^T x} + e^{\theta_0^T x}} = \frac{e^0}{e^{(\theta_1 - \theta_0)^T x} + e^0}$
- 参数量翻倍，参数存在冗余，但更容易理解

二分类逻辑回归的另一种形式

逻辑回归模型

多分类模型

多分类逻辑回归本质是从一系列 $[\theta_1^T x, \theta_2^T x, \dots, \theta_k^T x]$ 中选择最大值



多分类逻辑回归

- 类1的概率 $p(y = 1|x) = \frac{e^{\theta_1^T x}}{e^{\theta_1^T x} + e^{\theta_2^T x} + e^{\theta_3^T x} + e^{\theta_4^T x}}$
- 类2的概率 $p(y = 2|x) = \frac{e^{\theta_2^T x}}{e^{\theta_1^T x} + e^{\theta_2^T x} + e^{\theta_3^T x} + e^{\theta_4^T x}}$
- 类3的概率 $p(y = 3|x) = \frac{e^{\theta_3^T x}}{e^{\theta_1^T x} + e^{\theta_2^T x} + e^{\theta_3^T x} + e^{\theta_4^T x}}$
- 类4的概率 $p(y = 4|x) = \frac{e^{\theta_4^T x}}{e^{\theta_1^T x} + e^{\theta_2^T x} + e^{\theta_3^T x} + e^{\theta_4^T x}}$
- 如果存在类别 p , 对于其它所有类别都满足 $\theta_p^T x > \theta_i^T x$,


则 x 属于类别 p , 即 $p = \underset{i=1}{\operatorname{argmax}} \theta_i^T x$

逻辑回归模型

Softmax

Softmax 函数将线性回归值 $[\theta_1^T x, \theta_2^T x, \dots, \theta_k^T x]$ 归一化成概率

- 类别 $C = \{c_1, c_2, \dots, c_k\}$, 参数 $\theta = \{\theta_1, \theta_2, \dots, \theta_k\}$
- 第 c_j 类的预测概率 $p(y = c_j|x) = \text{Softmax}(\theta_j^T x) = \frac{e^{\theta_j^T x}}{\sum_{i=1}^k e^{\theta_i^T x}}$
- 可以标准化成 $k - 1$ 组参数



逻辑回归模型

交叉熵损失

交叉熵损失本质是在衡量两个分布间的距离

二值交叉熵

真实标签	y	$1 - y$
预测概率	p	$1 - p$

$$\mathcal{L} = -y \log p - (1 - y) \log(1 - p)$$

一般交叉熵

真实标签	y_1	y_2	y_3	$\dots$	y_k
预测概率	p_1	p_2	p_3	$\dots$	p_k

$$\mathcal{L} = -y_1 \log p_1 - y_2 \log p_2 - \dots - y_k \log p_k = -\sum_{i=1}^k y_i \log p_i$$

逻辑回归模型

交叉熵损失

交叉熵损失本质是在衡量两个分布间的距离

交叉熵损失

- 离散的情况 $H(p, q) = -\sum_x p(x) \log q(x)$
- 连续的情况 $H(p, q) = -\int_x p(x) \log q(x) dx$

分类问题计算交叉熵损失

真实值	0	1	0	0	0
预测值	0.1	0.6	0.05	0.05	0.2

逻辑回归模型

交叉熵损失

交叉熵损失本质是在衡量两个分布间的距离


交叉熵损失

- 离散的情况 $H(p, q) = -\sum_x p(x) \log q(x)$
- 连续的情况 $H(p, q) = -\int_x p(x) \log q(x) dx$

KL散度

$$KL(p, q) = H(p, q) - H(p)$$

- 衡量两个分布的距离：恒大于0，两者相等时为0，不对称
- 离散的情况 $KL(p, q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$
- 连续的情况 $KL(p, q) = \int_x p(x) \log \frac{p(x)}{q(x)} dx$



逻辑回归模型

梯度计算

□ 对一个示例的学习 $(x, y = c_j)$

- 最大对数化似然(log-likelihood)

$$\max_{\theta} \log p_{\theta}(y = c_j | x)$$

- 梯度

$$\begin{aligned} \frac{\partial \log p_{\theta}(y = c_j | x)}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \log \frac{e^{\theta_j^{\top} x}}{\sum_{k=1}^m e^{\theta_k^{\top} x}} \\ &= x - \frac{\partial}{\partial \theta_j} \log \sum_{k=1}^m e^{\theta_k^{\top} x} \\ &= x - \frac{e^{\theta_j^{\top} x}}{\sum_{k=1}^m e^{\theta_k^{\top} x}} x = (1 - p_{\theta}(y = c_j | x)) x \end{aligned}$$


逻辑回归模型

优缺点

维度	优点	缺点
表达能力	简单稳定	只能线性
计算效率	快	—
可解释性	很强	—
泛化能力	不易过拟合	依赖特征
数据要求	概率建模合理	对异常值敏感
应用场景	医疗/金融	不适合复杂任务



逻辑回归模型

优缺点



逻辑回归模型

优缺点



逻辑回归模型

评价指标


	预测	
	1	0
标签	1	True Positive False Negative
	0	False Positive True Negative

□ True / False

- True: 预测 = 标签
- False: 预测 $\neq$ 标签

□ Positive / Negative

- Positive: 预测 $y = 1$
- Negative: 预测 $y = 0$



逻辑回归模型

评价指标

精度(Accuracy)

- 分类正确的样本占样本总数的比例

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

		预测	
		1	0
标签	1	True Positive	False Negative
	0	False Positive	True Negative

逻辑回归模型

评价指标

精确率(Precision)

- 预测为1的样本中标签为1的比例

$$\text{Precision} = \frac{TP}{TP + FP}$$

	预测	
	1	0
标签	1	True Positive False Negative
	0	False Positive True Negative

召回率(Recall)

- 标签为1的样本中预测为1的比例

$$\text{Recall} = \frac{TP}{TP + FN}$$

	预测	
	1	0
标签	1	True Positive False Negative
	0	False Positive True Negative

逻辑回归模型

评价指标


□ 精确率和召回率的权衡

$$\hat{y} = \begin{cases} 1, & p_{\theta}(y = 1|x) > h \\ 0, & \text{otherwise} \end{cases}$$

- 阈值越高，精确率越高，召回率越低
 - 极端情况：阈值=0.99
- 阈值越低，精确率越低，召回率越高
 - 极端情况：阈值=0

□ F1分数


$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$



逻辑回归模型

评价指标

基于排序的度量：ROC曲线下面积（AUC）



https://www.bilibili.com/video/BV1wz4y197LU/?spm_id_from=333.337.search-card.all.click&vd_source=bf03710ca4c00725bbff8fbca92274f