



支持向量机

Support Vector Machine

 课程名称：机器学习


 章节：第8章 支持向量机

 授课人：魏军


最优超平面

问题引入

找到一个超平面，使其尽可能将两类数据点分开，同时使两类数据点距离分类超平面最远



二分类逻辑回归



哪一个超平面是最好的？

可以找到多个超平面将数据分开，但离超平面很近的点容易被误分类。如果可以让离超平面比较近的点尽可能的远离超平面，那么分类效果会更好


- 分类的准确性
- 分类的稳定性

应选择“正中间”，容忍性好，鲁棒性高，泛化能力最强

最大间隔超平面

概念介绍

所有样本点不仅可被超平面分开，还要和超平面保持尽可能大的距离



- 超平面: $w^T x + b = 0$
- 正类: 超平面上方的样本, $y = +1$
- 负类: 超平面下方的样本, $y = -1$
- 分类规则: $\hat{y} = \text{sign}(w^T x + b)$
- 间隔边界: 和超平面平行的两条虚线
- 支持向量: 间隔边界穿过的样本点
- 支持向量对分类超平面起绝对作用
- 间隔: 间隔边界之间的几何距离 d
- 目标: 保持分类准确性的同时最大化间隔 d


硬间隔SVM

Hard-margin SVM

简化超平面方程

简化形式

超平面方程参数存在冗余，可以精简方便后续运算



$$w^T x + b = c$$

$$w^T x + b = 0$$

$$w^T x + b = -c$$



$$\frac{w^T}{c} x + \frac{b}{c} = 1$$

$$\frac{w^T}{c} x + \frac{b}{c} = 0$$

$$\frac{w^T}{c} x + \frac{b}{c} = -1$$



$$w'^T x + b' = 1$$

$$w'^T x + b' = 0$$


$$w'^T x + b' = -1$$



计算间隔d

超平面法线方向影响了间隔大小

已知超平面上一点 x_0 ，以及超平面法线方向 a ，计算超平面方程




$$a^T(x - x_0) = 0$$

$$a^T x - a^T x_0 = 0$$

$$w^T x + b = 0$$


超平面方程中 x 前系数代表超平面法线方向



间隔 d 只与法线的模长相关，且成反比关系

优化目标

在保证分类准确性的同时最大化分类间隔



目标函数 $\max \frac{2}{\|w\|_2}$


约束条件

- 正类: $y = +1, \quad w^T x + b \geq 1$
- 负类: $y = -1, \quad w^T x + b \leq -1$
- 融合: $y(w^T x + b) \geq 1$

优化目标

转换形式

在保证分类准确性的同时最大化分类间隔



$$\begin{aligned} & \max \frac{2}{\|w\|_2} \\ \text{s.t. } & y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

$$\begin{aligned} & \min \frac{\|w\|_2}{2} \\ \text{s.t. } & y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

$$\begin{aligned} & \min \frac{\|w\|_2^2}{2} \\ \text{s.t. } & y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

$$\begin{aligned} & \min \frac{1}{2} w^T w \\ \text{s.t. } & y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

如何求解带不等式约束的函数最小值？

优化求解

等式约束下的拉格朗日乘子法

本质是让目标函数的梯度方向与约束函数的梯度方向平行

带等式约束的优化问题，可行解须位于 $g_i(x)$ 的边界上

$$\begin{aligned} \min_x & f(x) \\ \text{s.t. } & g_i(x) = 0, \quad i = 1, \dots, n \end{aligned}$$


引入拉格朗日乘子改造成无约束优化目标函数

$$L(x, \alpha) = f(x) + \sum_{i=1}^n \alpha_i g_i(x)$$

分别计算新函数 $L(x, \alpha)$ 对 x, α 的梯度

$$\nabla_x L(x, \alpha) = \nabla_x f(x) + \sum_{i=1}^n \alpha_i \nabla_x g_i(x) = 0$$

$$\nabla_{\alpha_i} L(x, \alpha) = g_i(x) = 0$$



$$\min_{x,y} f(x, y) = x^2 + y^2$$

$$\text{s.t. } g(x, y) = \frac{(x-1)^2}{0.5^2} + \frac{(y-1)^2}{0.25^2} = 0$$

$\Downarrow$

$$\nabla_{x,y} f(x, y) = \alpha \nabla_{x,y} g(x, y)$$

优化求解 不等式约束下的拉格朗日乘子法

不等式约束条件下，拉格朗日乘子法仍然可行

带不等式约束的优化问题，可行解须位于 $g_i(x)$ 区域内

$$\begin{aligned} \min_x & f(x) \\ \text{s.t. } & g_i(x) \leq 0, \quad i = 1, \dots, n \end{aligned}$$


引入拉格朗日乘子改造成无约束优化目标函数

$$L(x, \alpha) = f(x) + \sum_{i=1}^n \alpha_i g_i(x)$$

分别计算新函数 $L(x, \alpha)$ 对 x, α 的梯度

$$\nabla_x L(x, \alpha) = \nabla_x f(x) + \sum_{i=1}^n \alpha_i \nabla_x g_i(x) = 0$$

$$\nabla_{\alpha_i} L(x, \alpha) = g_i(x) = 0$$



$$\min_{x,y} f(x, y) = x^2 + y^2$$


$$\text{s.t. } g(x, y) = \frac{(x-1)^2}{0.5^2} + \frac{(y-1)^2}{0.25^2} \leq 0$$

$\Downarrow$

$$\nabla_{x,y} f(x, y) = \alpha \nabla_{x,y} g(x, y)$$

优化求解

不等式约束下的拉格朗日乘子法



$$\min_{x,y} f(x, y) = x^2 + y^2$$


$$g_1(x, y) = a_1x + b_1y + c_1 \leq 0$$

$$g_2(x, y) = a_2x + b_2y + c_2 \leq 0$$

$$g_3(x, y) = a_3x + b_3y + c_3 \leq 0$$

$$g_4(x, y) = a_4x + b_4y + c_4 \leq 0$$

$$g_5(x, y) = a_5x + b_5y + c_5 \leq 0$$



$$\min_{x,y} f(x, y) = x^2 + y^2$$

$$g_1(x, y) = a_1x + b_1y + c_1 \leq 0$$

$$g_2(x, y) = a_2x + b_2y + c_2 \leq 0$$

只有部分约束条件起作用，其余条件不起作用

$$\nabla_x L(x, \alpha) = \nabla_x f(x) + \sum_{i=1}^n \alpha_i \nabla_x g_i(x) = 0$$

目标函数的梯度与多个约束函数梯度的矢量和平行

$$L(x, \alpha) = f(x) + \sum_{i=1}^n \alpha_i g_i(x)$$

- $g_i(x)$ 起作用, $g_i(x) = 0$
- $g_i(x)$ 不起作用, $\alpha_i = 0$
- $\alpha_i g_i(x) = 0$
- $\alpha_i \geq 0$

模型求解

原问题转换为 minmax 问题

带约束条件的原问题

$$\min_{w,b} f(w,b) = \frac{1}{2} w^T w, \quad s.t. \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n$$

不带约束条件的 minmax 问题

带约束条件不如无约束条件好处理，所以引入拉格朗日乘子 α_i ，把约束条件整合进目标函数

$$L(w,b,\alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i(w^T x_i + b)]$$

优化目标变为

$$\min_{w,b} \max_{\alpha_i} L(w,b,\alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i(w^T x_i + b)]$$

α_i 可以理解成第 i 个约束的重要程度，且 $\alpha_i \geq 0$

- 如果某个样本离边界很远，它的约束不紧，通常对应： $\alpha_i = 0$
- 如果某个样本正好卡在间隔边界上，它对边界有影响，通常对应： $\alpha_i > 0$

模型求解

原问题转换为 minmax 问题

原问题和 minmax 问题具有相同最优解

原优化问题 $\min_{w,b} f(w, b) = \frac{1}{2} w^T w, \quad s.t. \ y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n$

minmax问题 $\min_{w,b} \max_{\alpha} L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i(w^T x_i + b)], \quad s.t. \ \alpha_i \geq 0, \quad i = 1, \dots, n$

证明过程

当样本 x_i 满足约束条件时, 即 $1 - y_i(w^T x_i + b) \leq 0$

$$\max_{\alpha \geq 0} L(w, b, \alpha) = f(w, b) = \frac{1}{2} w^T w$$

当样本 x_i 不满足约束条件时, 即 $1 - y_i(w^T x_i + b) > 0$

$$\max_{\alpha \geq 0} L(w, b, \alpha) = +\infty$$

由于损失太大, 外层 $\min_{w,b}$ 函数会调整参数 w, b , 使 x_i 重新满足约束条件

模型求解 minmax 问题转换为对偶问题

minmax 问题和对偶问题

minmax 优化目标, 直接找 w, b

$$\min_{w,b} \max_{\alpha} L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i (w^T x_i + b)], \quad s.t. \alpha_i \geq 0, \quad i = 1, \dots, n$$

对偶问题交换优化顺序, 先假设每个约束的权重 α_i , 再看在这些权重下最优的 w, b 是什么

$$\max_{\alpha} \min_{w,b} L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i (w^T x_i + b)], \quad s.t. \alpha_i \geq 0, \quad i = 1, \dots, n$$

minmax 问题最优解 $\geq$ 对偶问题的最优解

$$H(w, b) = \max_{\alpha} L(w, b, \alpha) \geq L(w, b, \alpha) \geq \min_{w,b} L(w, b, \alpha) = V(\alpha)$$

$$\min_{w,b} H(w, b) \geq \max_{\alpha} V(\alpha)$$

$$\min_{w,b} \max_{\alpha} L(w, b, \alpha) \geq \max_{\alpha} \min_{w,b} L(w, b, \alpha)$$

模型求解

对偶问题求解

因为 SVM 是凸优化问题，并且满足一定条件，所以强对偶成立，解对偶问题可以得到原问题的最优解

$$\min_{w,b} \max_{\alpha_i} L(w, b, \alpha) = \max_{\alpha_i} \min_{w,b} L(w, b, \alpha)$$

最优超平面方向 w 是训练样本的线性组合，且只有 $\alpha_i > 0$ 的支持向量会参与决定 w

$$\max_{\alpha_i} \min_{w,b} L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i (w^T x_i + b)]$$

求解第一步优化目标 $\min_{w,b} L(w, b, \alpha)$ ，将拉格朗日函数对参数 w 和 b 求偏导，得到

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0 \quad \Rightarrow \quad 0 = \sum_{i=1}^n \alpha_i y_i$$

模型求解

对偶问题求解

将上述条件 $w = \sum_{i=1}^n \alpha_i y_i x_i$, $0 = \sum_{i=1}^n \alpha_i y_i$ 带入拉格朗日函数 $L(w, b, \alpha)$

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i [1 - y_i (w^T x_i + b)] \\ &= \frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i - w^T \sum_{i=1}^n \alpha_i y_i x_i - b \sum_{i=1}^n \alpha_i y_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} w^T w \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i x_i \right)^T \left(\sum_{i=1}^n \alpha_i y_i x_i \right) \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

模型求解

对偶问题求解

求解第二步优化目标 $\max_{\alpha_i} \min_{w,b} L(w, b, \alpha)$

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j, \quad s.t. \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, n$$

添加负号

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i, \quad s.t. \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, n$$

模型求解

对偶问题求解

- 求解上述约束最优化问题，得到最优解 α^*

- 代入 $w = \sum_{i=1}^n \alpha_i y_i x_i$ ，得到

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$$

- 找一个支持向量 ($\alpha_i^* > 0$)，根据 $y_i(w^{*T} x_i + b^*) = 1$ 计算

$$b^* = y_i - w^{*T} x_i$$

- 求得分离超平面

$$w^{*T} x + b^* = 0$$

- 得到分类决策函数

$$f(x) = \text{sign}(w^{*T} x + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i x_i^T x + b^*\right)$$

模型小结

直接求解原问题是完全可以行的，为何还要用对偶方式求解？

$$\min \frac{1}{2} w^T w \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n$$

求解对偶问题具有以下优势

- 高维数据时变量更少：参数量 $d + 1 \rightarrow$ 样本量 n
- 自动识别支持向量： $\alpha_i > 0 \Rightarrow x_i$ 是支持向量
- 能够引入核函数： $x_i^T x_j \rightarrow K(x_i, x_j)$ ，从而实现非线性分类；对于线性 SVM，求对偶问题主要是为了计算效率和理论分析；对于核 SVM，求对偶问题则是必不可少的，因为核技巧只能在对偶形式中出现

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, n$$



软间隔SVM

Soft-margin SVM

真实数据问题

问题引入



样本可能包含噪声，分类完全正确的超平面不一定就是最好的



真实数据问题

问题引入


样本数据本身就不是线性可分的



改造约束条件

松弛因子

引入松弛因子 ξ 对约束条件放松



线性可分

- 优化目标: $\min \frac{1}{2} \|w\|^2$
- 约束条件: $y(w^T x + b) \geq 1$


非线性可分

- 负间隔边界外: $y(w^T x + b) > 1$
- 负间隔边界上: $y(w^T x + b) = 1$
- 负间隔边界和超平面间: $1 > y(w^T x + b) \geq 0$
- 超平面和正间隔边界间: $0 > y(w^T x + b) \geq -1$
- 正间隔边界外: $-1 > y(w^T x + b) \geq 1 - \xi$
- 综合条件: $y(w^T x + b) \geq 1 - \xi$

改造约束条件

松弛因子

引入松弛因子 ξ 对约束条件放松



$$y(w^T x + b) \geq 1 - \xi$$

- $\xi = 0$: 样本位于间隔外侧，分类完全正确
- $0 < \xi < 1$: 样本位于间隔内部，分类正确但不稳定
- $\xi > 1$: 样本位于超平面另一侧，被错误分类
- 只有“离群点”才有松弛因子，没离群的点 $\xi = 0$
- ξ 的值实际标出了离群点距间隔边界的距离，即**样本错误分类程度的大小**

优化目标

硬间隔 SVM

优化目标：最大化分类间隔

$$\min \frac{1}{2} \|w\|^2 \quad s.t. \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, 2, \dots, n$$

软间隔 SVM

优化目标：最大化分类间隔 + 最小化分类错误

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad s.t. \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, 2, \dots, n$$

超参数 C (惩罚系数)

- $C \rightarrow +\infty$: 惩罚无穷大, 不允许任何松弛, 退化为硬间隔 SVM
- C 很大: 严厉惩罚错分, 容忍较少错误, 间隔较窄, 易过拟合, 将噪声样本误认为正确样本
- C 很小: 对错分惩罚轻, 容忍更多错误, 间隔较宽, 易欠拟合, 将正确样本误认为噪声样本

模型求解

构建拉格朗日函数，将优化目标转化为无约束的优化函数

α_i 和 β_i 均为拉格朗日乘子, $\alpha_i \geq 0, \beta_i \geq 0, i = 1, 2, \dots, n$

$$L(w, b, \xi, \alpha, \beta) = \frac{1}{2}w^T w + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (1 - \xi_i - y_i(w^T x_i + b)) - \sum_{i=1}^n \beta_i \xi_i$$

将原始问题转换为对偶问题

将拉格朗日函数 $L(w, b, \xi, \alpha, \beta)$ 对参数 w, b 和 ξ 求偏导

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0 \quad \Rightarrow \quad 0 = \sum_{i=1}^n \alpha_i y_i$$

$$\frac{\partial L}{\partial \xi_i} = 0 \quad \Rightarrow \quad C = \alpha_i + \beta_i$$

模型求解

将上述条件 $w = \sum_{i=1}^n \alpha_i y_i x_i$, $0 = \sum_{i=1}^n \alpha_i y_i$, $C = \alpha_i + \beta_i$ 带入拉格朗日函数 $L(w, b, \xi, \alpha, \beta)$

$$\begin{aligned} L(w, b, \xi, \alpha, \beta) &= \frac{1}{2} w^T w + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (1 - \xi_i - y_i (w^T x_i + b)) - \sum_{i=1}^n \beta_i \xi_i \\ &= \frac{1}{2} w^T w + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \alpha_i \xi_i - w^T \sum_{i=1}^n \alpha_i y_i x_i - b \sum_{i=1}^n \alpha_i y_i - \sum_{i=1}^n \beta_i \xi_i \\ &= \frac{1}{2} w^T w + \sum_{i=1}^n (C - \alpha_i - \beta_i) \xi_i + \sum_{i=1}^n \alpha_i - w^T w - b \sum_{i=1}^n \alpha_i y_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} w^T w = \sum_{i=1}^n \alpha_i - \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i x_i \right)^T \left(\sum_{i=1}^n \alpha_i y_i x_i \right) \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

模型求解

硬间隔SVM只有 $\alpha_i \geq 0$, 软间隔SVM多了上界 $\alpha_i \leq C$

将原始问题转化为对偶问题, 其中 $\alpha_i \leq C$ 由 $C - \alpha_i - \beta_i = 0$ 且 $\alpha_i \geq 0, \quad \beta_i \geq 0$ 得

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

添加符号

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad \text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

C 从根本上决定了单个样本拉动决策边界的能力上限

- α_i 是第 i 个样本对分类超平面的贡献权重
- C 是单个样本贡献权重的上限
- 限制噪声点和离群点对决策边界的过度影响

模型求解

- 求解上述对偶问题, 得到最优解 α^*
- 代入 $w = \sum_{i=1}^n \alpha_i y_i x_i$, 得到

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$$

- 找一个支持向量 ($0 < \alpha_i^* < C$), 根据 $y_i(w^{*T} x_i + b^*) = 1$ 计算

$$b^* = y_i - w^{*T} x_i$$

- 求得分离超平面

$$w^{*T} x + b^* = 0$$

- 得到分类决策函数

$$f(x) = \text{sign}(w^{*T} x + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i x_i^T x + b^*\right)$$

模型对比

对比项	硬间隔SVM (Hard Margin)	软间隔SVM (Soft Margin)
适用数据	完全线性可分，无噪声	线性不可分或含噪声
优化目标	最大化间隔	最大化间隔 + 最小化分类错误
松弛变量 ξ_i	无	有
超参数 C	无	有
约束条件	$y_i(w^T x_i + b) \geq 1$	$y_i(w^T x_i + b) \geq 1 - \xi_i$
容错性	零容错，有错误则无解	允许少量错分
对噪声敏感性	高	低
泛化能力	容易受离群点影响	更强
对偶变量约束	$\alpha_i \geq 0$	$0 \leq \alpha_i \leq C$
实际应用	很少单独使用	最常用



非线性SVM

Nonlinear SVM

真实数据问题



问题引入

现实中很多数据是非线性分布的，无论如何画直线，都无法将两类样本分开



数据升维

对非线性可分数据进行升维，升维后线性可分



数据升维

非线性SVM的本质是在高维特征空间中寻找最大间隔超平面

对于原空间中的样本：

$$x = (x_1, x_2)$$

通过映射函数 $\phi(x)$ 将其映射到高维空间


$$x \rightarrow \phi(x)$$

原本线性不可分数据，在高维空间线性可分，例如

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

分类决策函数可表示为

$$f(x) = \text{sign}(w^T \phi(x) + b)$$



2维数据(线性不可分) → 3维数据(线性可分)

核技巧 Kernel Trick

将低维数据映射到高维数据后使用线性SVM优化

优化目标:
$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j) - \sum_{i=1}^n \alpha_i, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

决策函数:
$$f(x) = \text{sign}(w^{*T} x + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i \phi(x_i)^T \phi(x) + b^*\right)$$

直接显式计算 $\phi(x)$ 的致命缺陷：维度爆炸，计算存储成本极高；只能升到有限维，无法处理无限维

- 假设原始样本是2维特征 $x = (x_1, x_2)$ ， $\phi(x)$ 是2阶多项式映射，则升维后变成 3 维

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

- 假设原始样本是 d 维特征 $x = (x_1, x_2, \dots, x_d)$ ， $\phi(x)$ 是2阶多项式映射，则升维后变成 D 维

$$D = \frac{d(d+1)}{2}$$

- 假设原始样本是 d 维特征 $x = (x_1, x_2, \dots, x_d)$ ， $\phi(x)$ 是 p 阶多项式映射，则升维后维度爆炸

核技巧

Kernel Trick

间接隐式计算 $\phi(x)$ 的可能：优化函数和决策函数中只出现样本内积 $\phi(x_i)^T \phi(x_j)$

优化函数:
$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j) - \sum_{i=1}^n \alpha_i, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

决策函数:
$$f(x) = \text{sign}(w^{*T} x + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i \phi(x_i)^T \phi(x) + b^*\right)$$

定义核函数 $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$ ，直接计算高维空间内积，无需显式计算 $\phi(x)$ ，这就是核技巧

优化函数:
$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^n \alpha_i, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n$$

决策函数:
$$f(x) = \text{sign}(w^{*T} x + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i K(x_i, x) + b^*\right)$$

常见核函数

Kernel Trick

定理表明：只要一个对称函数对应的核矩阵半正定，它就能作为核函数使用

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

利用核技巧隐式完成高维映射，在高维空间中构造最大间隔分类超平面，从而解决非线性分类问题

核函数	表达式	特点
线性核 Linear Kernel	$K(x_i, x_j) = x_i^T x_j$	不升维，等价于线性SVM
多项式核 Polynomial Kernel	$K(x_i, x_j) = (x_i^T x_j + 1)^d$	可表示特征组合，适用于中等复杂非线性问题
高斯核 RBF Kernel	$K(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ ^2}{2\sigma^2}\right)$	无限维映射，表达能力强，应用最广泛
Sigmoid核	$K(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$	来源于神经网络，使用较少

模型求解

- 求解上述对偶问题，得到最优解 α^*
- 代入 $w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$ ，得到

$$w^* = \sum_{i=1}^n \alpha_i^* y_i \phi(x_i)$$

- 选取 α^* 的一个正分量 α_j^* ，据此计算

$$b^* = y_j - w^{*T} \phi(x_j) = y_j - \sum_{i=1}^n \alpha_i^* y_i \phi(x_i)^T \phi(x_j) = y_j - \sum_{i=1}^n \alpha_i^* y_i K(x_i, x_j)$$

- 求得分离超平面

$$w^{*T} \phi(x) + b^* = 0$$

- 得到分类决策函数

$$f(x) = \text{sign}(w^{*T} \phi(x) + b^*) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i \phi(x_i)^T \phi(x) + b^*\right) = \text{sign}\left(\sum_{i=1}^n \alpha_i^* y_i K(x_i, x) + b^*\right)$$

非线性SVM的优缺点

优点	缺点
能处理线性不可分问题	核函数及参数选择困难
核技巧实现高维映射，无需显式升维	训练复杂度较高，不适合超大规模数据
小样本情况下表现优异	训练时间随样本数快速增长
具有良好的泛化能力	模型可解释性较差
优化问题为凸优化，能获得全局最优解	对超参数 C 较敏感
适用于高维数据分类	多分类问题实现相对复杂

SVM算法总结

优点

- 解决高维特征的分类问题和回归问题很有效,在特征维度大于样本数时依然有很好的效果
- 仅仅使用一部分支持向量来做超平面的决策, 无需依赖全部数据
- 有大量的核函数可以使用, 从而可以很灵活的来解决各种非线性的分类回归问题
- 样本量不是海量数据的时候, 分类准确率高, 泛化能力强

缺点

- 如果特征维度远远大于样本数, 则SVM表现一般
- SVM在样本量非常大, 核函数映射维度非常高时, 计算量过大, 不太适合使用
- 非线性问题的核函数的选择没有通用标准, 难以选择一个合适的核函数
- SVM对缺失数据敏感

SVM通过最大化分类间隔构建最优分类超平面, 对于线性不可分问题利用核函数实现高维映射, 是一种具有良好泛化能力和坚实理论基础的经典机器学习算法